UNIVERSIDADE REGIONAL DE BLUMENAU

CENTRO DE CIÊNCIAS EXATAS E NATURAIS

CURSO DE CIÊNCIA DA COMPUTAÇÃO – BACHARELADO

PROTÓTIPO DE SOFTWARE PARA LEITURA LABIAL

MARCO AURÉLIO CARAMORI

BLUMENAU
2012

2012/2-19

MARCO AURÉLIO CARAMORI

PROTÓTIPO DE SOFTWARE PARA LEITURA LABIAL

Trabalho de Conclusão de Curso submetido à Universidade Regional de Blumenau para a obtenção dos créditos na disciplina Trabalho de Conclusão de Curso II do curso de Ciência da Computação — Bacharelado.

Prof. Dalton Solano dos Reis, Mestre - Orientador

BLUMENAU
2012

2012/2-19

PROTÓTIPO DE SOFTWARE PARA LEITURA LABIAL

Por

MARCO AURÉLIO CARAMORI

Trabalho aprovado para obtenção dos créditos na disciplina de Trabalho de Conclusão de Curso II, pela banca examinadora formada por:

Presidente:	Prof. Dalton Solano dos Reis, Mestre – Orientador, FURB
Membro:	Prof. Aurélio Faustino Hoppe, Mestre - FURB
Membro:	Prof. Antonio Carlos Tavares, Mestre - FURB

Blumenau, 11 de dezembro de 2012

À minha vó Felomena Caramori e seu dom de simplificação da vida.

AGRADECIMENTOS

Aos meus pais por me proporcionarem um cenário parcialmente kafkiano para a criação do meu eu.

Ao Pastafarianismo por me fornecer os alicerces da minha fé renovadora.

À arte.

Ao orientador deste trabalho, Dalton Solano dos Reis, pela confiança e condução desta ideia até o fim.

Impossibilidades prováveis são sempre preferíveis a improváveis possibilidades.

Aristóteles

RESUMO

A leitura labial é uma técnica utilizada para extrair informações dos lábios, língua ou face, que possam auxiliar no reconhecimento da fala e é amplamente utilizada por portadores de deficiências auditivas. Tendo em vista a automatização desta atividade, existem várias fases de processamento computacional necessárias, sendo elas: aquisição das imagens, extração das características, reconhecimento de padrões e classificação de novas amostras. Este trabalho apresenta um protótipo de software para efetuar a leitura labial utilizando os dados relativos às alterações das medidas dos lábios durante a fala. A aquisição das imagens de vídeo é feita a partir de uma câmera de vídeo convencional, acoplada a um computador *desktop.* A extração das características do contorno labial é feita utilizando técnicas de processamento de imagem, enquanto a identificação de padrões e classificação de novas amostras é feita utilizando um algoritmo de filtro de Bayes. O protótipo foi avaliado com um banco de amostras próprio, coletadas de um único indivíduo, resultando em uma taxa de acerto de oitenta por cento.

Palavras-chave: Leitura labial. Leitura orofacial. Visão computacional. Filtro de Bayes.

ABSTRACT

Lip Reading is a technique to extract information from lips, tongue or face in order to provide extra information during speech and is widely applied by hearing impaired humans. Making this task computably possible requires basically three steps: acquiring the images from speech, extracting the features and finally classifying new samples. This work presents a prototype of lip reading software using the ratio of change from three lip measures over time. The images are captures through a video camera attached to a computer. The features are extracted using processing image techniques, while the classification is attained through a simple Bayes filter algorithm. The prototype was tested with a data set collected from a single individual, resulting in a success rate of eighty per cent.

Key-words: Lip reading. Speechreading. Computer vision. Bayes filter.

LISTA DE ILUSTRAÇÕES

Figura 1 - Cone bilateral representando a distribuição das cores no modelo HSV/HSI 19
Figura 2 - Algoritmo de Filtro Bayesiano 21
Figura 3 - Resultados durante a segmentação dos lábios na imagem da face 22
Quadro 1 - Características dos trabalhos correlatos 23
Figura 4 - Diagrama de casos de uso 25
Quadro 2 - Caso de uso UC01 26
Quadro 3 - Caso de uso UC02 27
Quadro 4 - Caso de uso UC03 28
Quadro 5 - Caso de uso UC04 29
Figura 5 - Diagrama de pacotes do protótipo de leitura labial 30
Figura 6 - Pacote `model` 30
Figura 7 - Pacote `utils` 32
Figura 8 - Pacote `infoextractor` 34
Figura 9 - Pacote `enum` 35
Figura 10 - Pacote `core` 36
Quadro 6 - Exemplo da utilização da captura para gravação de vídeos 40
Figura 11 - Imagem original e área de interesse 41
Figura 12 - Formatos e tamanhos do padrão no filtro da mediana 42
Quadro 7 - Utilização do filtro da mediana com a OpenCV 42
Figura 13 - Aplicação do filtro da mediana na área de interesse 42
Quadro 8 - Limiarização HSV 43
Figura 14 - Aplicação do algoritmo de limiarização com HSV 43
Quadro 9 - Aplicação da operação de erosão 44
Figura 15 - Aplicação do filtro da mediana após a limiarização com HSV 44
Figura 16 - Exemplo de ruído após a aplicação do filtro da mediana na limiarização HSV 44
Quadro 10 - Utilização da função de busca de contornos 45
Figura 17 - Contornos detectados pela função `findContours` 45
Figura 18 - Contornos equivalentes aos possíveis dentes 46
Quadro 11 - Criação do polígono convexo com a OpenCV 46
Figura 19 - Utilização do polígono convexo gerado com os dentes 47
Figura 20 - Processo final de extração do contorno 47

Figura 21 - Medidas utilizadas na extração das características 48
Quadro 12 - Atribuição da probabilidade inicial 49
Quadro 13 - Processo de atualização das probabilidades 50
Quadro 14 - Movimentação das probabilidades no espaço amostral 51
Figura 22 - Menu inicial da aplicação 52
Figura 23 - Contorno apresentado ao usuário para ajuste dos parâmetros 53
Figura 24 - Parâmetros disponíveis para alteração pelo usuário 53
Figura 25 - Controles para a gravação de vídeos 54
Figura 26 - Telas de notificação de espera e início da fala 54
Figura 27 - Menu para reconhecimento de fala 55
Figura 28 – Imagem apresentada durante o reconhecimento 56
Quadro 15 - Matriz de confusão por texto 61

LISTA DE TABELAS

Tabela 1 - Desempenho das principais etapas de processamento 62

SUMÁRIO

1 INTRODUÇÃO 13
1.1 OBJETIVOS DO TRABALHO 14
1.2 ESTRUTURA DO TRABALHO 14
2 FUNDAMENTAÇÃO TEÓRICA 15
2.1 LEITURA LABIAL 15
2.1.1 Aspectos da fala 15
2.1.2 Reconhecimento de fala 16
2.2 VISÃO COMPUTACIONAL 17
2.2.1 Sistemas de leitura labial 18
2.2.1.1 Segmentação dos lábios 18
2.2.1.2 Extração de características dos lábios 19
2.2.1.3 Classificação de fala 19
2.3 FILTRO DE BAYES 20
2.3.1 Algoritmo de Filtro Bayesiano 20
2.4 TRABALHOS CORRELATOS 21
3 DESENVOLVIMENTO DO PROTÓTIPO 24
3.1 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO 24
3.2 ESPECIFICAÇÃO 24
3.2.1 Casos de uso 25
3.2.1.1 Gravar vídeos da fala 25
3.2.1.2 Extrair características da fala 26
3.2.1.3 Processar banco de amostras 27
3.2.1.4 Reconhecer fala 29
3.2.2 Diagrama de classes 30
3.2.2.1 Pacote `model` 30
3.2.2.2 Pacote `utils` 31
3.2.2.3 Pacote `infoextractor` 33
3.2.2.4 Pacote `enum` 35
3.2.2.5 Pacote `core` 36
3.3 IMPLEMENTAÇÃO 38

3.3.1 Técnicas e ferramentas utilizadas 38
3.3.2 Etapas do processamento 39
3.3.2.1 Aquisição 39
3.3.2.2 Configuração dos parâmetros 40
3.3.2.3 Extração do contorno 41
3.3.2.4 Extração de características do contorno 48
3.3.2.5 Reconhecimento da fala 48
3.3.3 Operacionalidade da implementação 51
3.3.3.1 Gravar vídeos 52
3.3.3.2 Processar banco de amostras 54
3.3.3.3 Reconhecer a fala 55
3.4 RESULTADOS E DISCUSSÃO 56
3.4.1 Gravação dos vídeos 56
3.4.2 Definição da área de interesse e segmentação 57
3.4.3 Extração dos dados do movimento dos lábios 58
3.4.4 Classificação da fala 59
3.4.5 Execução de testes 60
3.4.5.1 Precisão 60
3.4.5.2 Desempenho 61
3.4.5.3 Memória 62
4 CONCLUSÕES 63
4.1 EXTENSÕES 63

1 INTRODUÇÃO

O reconhecimento de fala em áudio é uma área onde há grande investimento de pesquisa e implementação nos últimos tempos. Fornecendo conforto e acessibilidade na comunicação e interação homem-máquina, aplicações que vão desde robustos softwares para computadores de mesa até pequenos aplicativos para aparelhos celulares, estão disponíveis no mercado.

Estas aplicações começaram a surgir, em sua maior parte, no início da sexta geração de computadores, graças ao aumento significativo da capacidade computacional. Os estudos até então eram apenas viáveis em relação à implementação com recursos fornecidos por grandes universidades, não sendo possível a implementação em computadores pessoais.

O aumento da capacidade computacional tornou possível a utilização de redes neurais e modelos estatísticos na interpretação do áudio, que até o final dos anos de 1980 eram inviáveis. Sendo assim, a utilização do áudio foi explorada nas mais diversas formas, dando origem ao cenário atual em aplicações que utilizam a fala.

A utilização da fala, porém, requer alta precisão na interpretação dela, sendo este o maior problema atualmente para a área de estudo da frequência sonora, a qual possui atualmente o maior foco no desenvolvimento de soluções para esta tarefa. O processamento de áudio, assim como em processos que utilizam a imagem, envolve o tratamento de dados com uma grande quantidade de dados indesejados provenientes de sensores que efetuam leituras de todo o cenário, sendo neste caso um microfone ou uma câmera de vídeo, fazendo assim necessários processos que removem ou ignoram estas informações.

A utilização das imagens no processo de reconhecimento da fala tornou-se também um recurso muito importante em processos que utilizam a frequência sonora. Desta forma, processos que utilizam modelos estatísticos híbridos, por exemplo, processam tanto a representação visual quanto auditiva, fazendo com que a análise da fala seja mais aproximada da técnica de interpretação da fala entre humanos.

Este trabalho, portanto, tem como objetivo explorar as imagens durante o processo de comunicação humano, através da análise do movimento labial. Para que tal objetivo fosse alcançado, foram utilizadas técnicas de visão computacional, cuja entrada para o protótipo do sistema são imagens em vídeo de locutores efetuando a fala de algum valor textual pré-estabelecido. A partir destas imagens são utilizadas técnicas de processamento de imagem para extrair valores referentes às medidas dos lábios, fazendo por fim, uso de um algoritmo probabilístico de busca, para determinar o valor textual em imagens de vídeo sem informação

de áudio.

1.1 OBJETIVOS DO TRABALHO

O objetivo deste trabalho é desenvolver um protótipo de software para o reconhecimento da fala em imagens de vídeo.

Os objetivos específicos do trabalho são:

a) capturar informações relativas ao movimento dos lábios em imagens de vídeo;
b) utilizar uma técnica de inteligência artificial, para a geração de legendas para imagens de vídeo que contém locutores efetuando a fala de algum texto desconhecido.

1.2 ESTRUTURA DO TRABALHO

Este trabalho é apresentado em quatro capítulos, sendo neste primeiro capítulo apresentada uma breve introdução ao tema, os objetivos do trabalho e a estrutura o qual é apresentado.

O segundo capítulo contém a fundamentação teórica necessária para a compreensão do assunto e da solução implementada no protótipo.

O terceiro capítulo apresenta todo o processo de especificação do protótipo, onde são apresentados diagramas de caso de uso, de classes e de pacotes. Também são expostos detalhes da implementação além da operacionalidade do protótipo do ponto de vista do usuário.

O último capítulo, por sua vez, apresenta as conclusões a respeito dos resultados obtidos além de sugestões para trabalhos futuros.

2 FUNDAMENTAÇÃO TEÓRICA

Neste capítulo é apresentada uma introdução sobre a leitura labial abordando aspectos e o reconhecimento da fala durante a comunicação. Em seguida é feita a exposição sobre a área de visão computacional, a qual aborda sistemas de leitura labial. Aborda-se também a classe de algoritmos de filtro de Bayes e por último são relacionados três trabalhos correlatos.

2.1 LEITURA LABIAL

A percepção da fala pelo ser humano é efetuada, tendo como uma das principais fontes de dados, o sinal acústico produzido pelo transmissor no processo de comunicação. Este sinal por sua vez é produzido pela movimentação articulatória do trato vocal (MARTINO; MAGALHÃES, 2004, p. 1).

A leitura orofacial, também denominada leitura labial, é, segundo Summerfield (1992, p. 71, tradução nossa), "a percepção da fala puramente visual com a observação de movimentos gesticulatórios de quem efetua a fala".

Grande parte dos movimentos articulatórios durante a fala ocorre no interior da cavidade oral, sem que seja possível a visualização. Desta forma, a percepção visual torna-se menos capacitada para a discriminação da fala do que a percepção auditiva (MARTINO; MAGALHÃES, 2004, p. 1).

As características físicas de um indivíduo durante a fala (trato vocal, boca, lábios e cavidades nasais) são muito semelhantes, porém, aspectos comportamentais ou de saúde podem causar alterações com o tempo, o que dificulta ainda mais a distinção da fala através de informações visuais (JAIN; ROSS; NANDAKUMAR, 2011, p. 33).

2.1.1 Aspectos da fala

Durante a execução da fala, a configuração facial do locutor corresponde ao visema. O objetivo de um visema é representar visualmente os fonemas. Os fonemas, por sua vez, representam a informação acústica durante a fala, que podem também serem transcritos graficamente para o seu

equivalente chamado de grafema (SENNYEY; MONTIEL; CAPOVILLA, 2008, p. 207-209).

A classificação visual dos fonemas apresenta outra forma de classificação, que são os homofemas, que segundo Martino e Magalhães (2004, p. 1), “são segmentos sonoros que não são possíveis de serem diferenciados visualmente”.

2.1.2 Reconhecimento de fala

O reconhecimento da fala utilizando informações visuais é muito utilizado por deficientes auditivos. Embora deficientes auditivos não tenham acesso à informação sonora, eles são capazes de aprender indiretamente o valor de fonemas utilizando a informação visual e gráfica que os fonemas possuem (SENNYEY; MONTIEL; CAPOVILLA, 2008, p. 209).

Estudos demonstram que a percepção da fala utilizando somente aspectos sonoros nem sempre é capaz de produzir uma interpretação completa, exigindo em alguns casos a compreensão do contexto da comunicação e detecção de padrões referentes a cada indivíduo para que a comunicação seja feita com sucesso (LIEBERMAN, 1963, p. 185).

A percepção da fala utilizando dados visuais pode, portanto, representar um problema no processo de reconhecimento da fala, causando distorções na informação transmitida. Estudos como os efetuados por McGurk e McDonald (1976) demonstraram através de testes, que quando o fonema `/ga/` tem seu visema apresentado em vídeo com um áudio artificial representando o fonema `/ba/` os observadores passam a ter uma percepção de que o fonema `/da/` foi representado. Este estudo demonstrou que o reconhecimento do áudio, durante a comunicação humana, utiliza de forma inconsciente no ser humano as imagens dos lábios do locutor quando este está no campo visual do receptor. Também no estudo, quando os observadores possuem apenas o fonema como fonte de identificação do conteúdo textual, esses conseguem com sucesso classificar o fonema `/ga/`.

Em algumas situações, o ambiente no qual a fala é efetuada possui outros sinais acústicos que figuram como ruído, dificultando a interpretação do som. Desta forma, a utilização da imagem é frequentemente feita por indivíduos que possuem não só o sentido de visão como também de audição saudáveis (ERBER, 1975, p. 481).

2.2 VISÃO COMPUTACIONAL

Compreender o mundo real foi sempre uma atividade a qual cientistas e escritores sempre atribuíram a computadores. Tarefas simples do dia-a-dia são cada vez mais alvo de trabalhos científicos, que modelam e projetam soluções específicas para uma área que é relativamente nova na área de sistemas de computadores.

Um dos primeiros passos na compreensão do mundo real na área da computação é a captura das informações em algum formato de dados. Este formato de dados geralmente é composto por imagens capturadas a partir de câmeras de vídeo. Estas imagens são então processadas, utilizando um conjunto de técnicas estudadas pela área de processamento de imagens. Processamento de imagens é uma atividade que consiste basicamente na aplicação de operações em imagens, tendo como objetivo a melhoria ou modificação delas, e que não são de todo relevantes em um contexto geral, mas são feitas com o objetivo de atingir um resultado específico definido pelo usuário (PARKER, 2011, p. 285).

Visão computacional, por sua vez, é uma área da computação gráfica, que utilizando processamento de imagem e inteligência artificial, tem como objetivo, segundo Shapiro (2001, p. 13, tradução nossa), “tomar decisões úteis sobre objetos físicos e cenas reais, baseados em imagens sensoriais”.

Desta forma, problemas de visão computacional não envolvem somente a busca de objetos em uma imagem, e sim informações específicas sobre os objetos encontrados, como por exemplo: quantas pessoas entraram ou saíram de um estabelecimento ou a quantidade de frutos de má qualidade dentre um conjunto de frutos mistos.

Parker (2011, p. 289-290) define a existência das seguintes etapas usualmente encontradas na solução de problemas de visão computacional:

a) encontrar uma forma de isolar objetos que possam ser de interesse na imagem, utilizando técnicas de processamento de imagem e segmentação de imagens;
b) para cada objeto encontrado na segmentação, pesquisar por características que possam classificar objetos que são de interesse;
c) verificar se esta característica foi apenas encontrada em objetos que são de interesse. Em caso positivo, esta característica é apropriada para a solução do problema;
d) caso nem todos os objetos encontrados com a característica sejam de interesse, gravar um percentual de acerto com a característica atual, e repetir a etapa (c).

Para atingir a segmentação dos objetos utilizam-se algoritmos, como o de limiarização,

que define duas ou mais cores, atribuídas às regiões da imagem de acordo com um limite de valor dos pixels. Os objetos encontrados são então analisados de acordo com o formato, que por sua vez darão origem às características necessárias para a compreensão de determinada cena.

2.2.1 Sistemas de leitura labial

Tendo em vista que o processo de leitura labial envolve não somente a detecção dos objetos de interesse, os lábios, como também a interpretação do movimento labial efetuado, esta atividade é computacionalmente tratada, conforme o tópico supracitado, na área de visão computacional.

Sistemas de leitura labial envolvem geralmente três etapas: segmentação dos lábios, extração de características que possam identificar e classificar a fala e por fim o reconhecimento do texto falado levando em consideração algum vocabulário (SILVEIRA; FACON; BORGES, p. 1).

2.2.1.1 Segmentação dos lábios

A segmentação dos lábios é uma das tarefas mais difíceis durante o processo de leitura labial, e tem sido estudada extensivamente, buscando a melhor separação possível entre a região da pele e dos lábios (CAPLIER et al., 2009, p. 71).

A maioria das aplicações que efetuam leitura labial possuem dificuldades durante a fase de segmentação sendo elas principalmente relativas a ruídos faciais incluindo especificamente pelos faciais (barba ou bigode) (WANG et al., 2009, p. 150).

Atualmente grande parte dos métodos para a segmentação dos lábios inclui a verificação utilizando modelos de cores, como por exemplo, o modelo *Hue Saturation Intensity/Value* (HSI/ HSV) (WANG et al., 2009, p. 151).

Os modelos HSI/HSV representam a matiz, saturação e intensidade. O primeiro valor, matiz, é a cor a ser descrita, como por exemplo, amarelo ou vermelho, a saturação é a quantidade de cor presente, enquanto a intensidade representa a luz, que indica se é uma cor clara ou escura (ver Figura 1) (RUSS, 2011, p. 45).

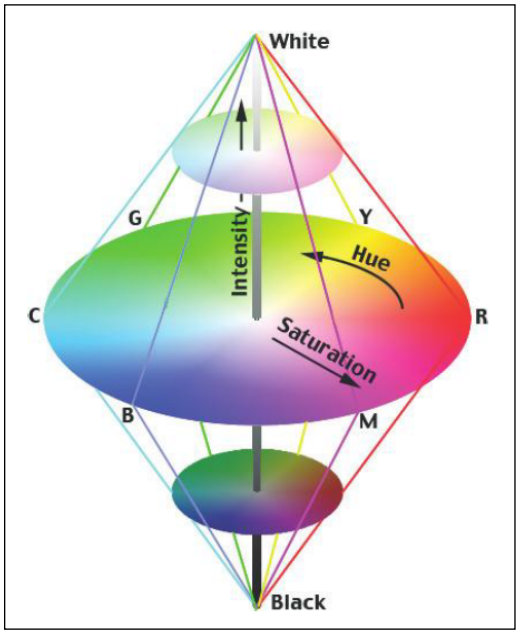

Fonte: Russ (2011, p. 45).

Figura 1 - Cone bilateral representando a distribuição das cores no modelo HSV/HSI

2.2.1.2 Extração de características dos lábios

A extração de características faciais é agrupada geralmente em três grupos: baseadas em aparências, baseadas em forma ou mistas (ALEKSIC; KATSAGGELOS, 2009, p. 41-42).

Características baseadas em aparência são extraídas utilizando, por exemplo, o valor de determinada intensidade para uma região de uma imagem, características baseadas em forma podem representar contornos ou modelos tridimensionais da face, enquanto características mistas combinam informações de características baseadas em formas e em aparências (ALEKSIC; KATSAGGELOS, 2009, p. 42).

2.2.1.3 Classificação de fala

Após a fase de segmentação dos lábios e extração das características, é necessária a análise das características para a classificação da fala. Para que essa atividade seja efetuada, é possível utilizar informações da fala de duas formas: capturando uma informação em um tempo específico, ou coletar informações relativas ao movimento. Na primeira forma características como formato de contorno ou medidas dos lábios são extraídas, enquanto na segunda forma, dados como velocidade ou taxa de variação das medidas são analisados entre uma imagem e

outra durante a fala (YAU; KUMAR; WEGHORN, 2009, p. 391).

2.3 FILTRO DE BAYES

Atualmente uma das formas mais populares de se estimar o estado atual em determinado cenário utiliza algoritmos aplicando um filtro Bayesiano (THRUN; BURGARD; FOX, 2005, p. 23).

Um filtro Bayesiano pode ser considerado um método baseado em partículas. Métodos baseados em partículas são aproximações da probabilidade de eventos em um determinado espaço amostral, com a criação de várias instâncias de variáveis que representam possíveis estados atuais (KOLLER; FRIEDMAN, 2009, p. 487).

Métodos baseados em partículas podem ser classificados de duas formas: partículas completas ou partículas fragmentadas. Partículas completas são partículas que cobrem determinado evento no espaço amostral, enquanto partículas fragmentadas cobrem determinado conjunto de eventos (KOLLER; FRIEDMAN, 2009, p. 487).

Filtros Bayesianos utilizam o conceito de distribuições probabilísticas da certeza de determinado evento ocorrer. Essa distribuição atribui uma probabilidade para cada possibilidade em comparação com observações do estado atual de um cenário (THRUN; BURGARD; FOX, 2005, p. 22).

2.3.1 Algoritmo de Filtro Bayesiano

O algoritmo de Filtro Bayesiano possui basicamente dois passos: predição e atualização das probabilidades baseando-se nas observações (THRUN; BURGARD; FOX, 2005, p. 23). Na Figura 2 é possível visualizar o formato básico do algoritmo de filtro Bayesiano.

Na primeira etapa (Figura 2 linha 3), o estado atual `x` no tempo `t` para determinada distribuição de probabilidade `bel` é calculado somando o produto de duas distribuições: a distribuição da probabilidade na observação anterior, e a probabilidade de uma ação `ut` causar uma transição de `xt-1` para `xt` (THRUN; BURGARD; FOX, 2005, p. 23).

Na segunda etapa (Figura 2 linha 4) é feito o cálculo de determinada observação `z1` ter

sido observada para cada probabilidade hipotética no estado `xt`. O produto final não é uma probabilidade e é então normalizado por uma constante `n`. Essa etapa gera a distribuição da probabilidade dos eventos possíveis de terem ocorrido em `bel` para determinado tempo `t` (THRUN; BURGARD; FOX, 2005, p. 23).

1: **Algorithm Bayes_filter**($bel(x_{t-1}), u_t, z_t$):
2: for all x_t do
3: $\overline{bel}(x_t) = \int p(x_t \mid u_t, x_{t-1})\, bel(x_{t-1})\, dx$
4: $bel(x_t) = \eta\, p(z_t \mid x_t)\, \overline{bel}(x_t)$
5: endfor
6: return $bel(x_t)$

Fonte: Thrun, Burgard e Fox (2005, p. 24).

Figura 2 - Algoritmo de Filtro Bayesiano

2.4 TRABALHOS CORRELATOS

Existem diversas pesquisas em andamento na área de leitura labial. Foram selecionados três projetos que possuem características semelhantes às funcionalidades implementadas neste trabalho. Sendo o primeiro de Shaikh et al. (2010), que explora o uso de máquinas de vetores de suporte e fluxo óptico, o segundo trabalho de Silveira, Facon e Borges (2003) que explora o uso de máquinas de vetores de suporte e medidas dos lábios e o terceiro de Hojo e Hamada (2009) que utiliza pontos de interesse dos lábios.

No trabalho apresentado por Shaikh et al. (2010) é proposta uma técnica que aplica inteligência artificial e fluxo óptico, consistindo de duas etapas. Na primeira etapa de treinamento, máquinas de vetores de suporte são utilizadas com os dados do fluxo óptico obtidas com a diferença entre sequências de imagens durante a efetuação de um visema por um locutor. Na segunda etapa, o software é capaz de efetuar a leitura de imagens de vídeo e predizer os fonemas efetuados nestas imagens com a utilização das máquinas de vetores de suporte. Durante o processo o locutor permanece estático durante as duas fases e as condições ambientais são controladas. Os fonemas analisados constituem um grupo heterogêneo de vogais e consoantes no idioma inglês. Neste trabalho obteve-se resultado de precisão de 95,9%, especificidade de 98,1% e sensitividade de 66,4%, para o grupo de visemas analisados.

No segundo trabalho, apresentado por Silveira, Facon e Borges (2003), propõe-se a utilização de técnicas de processamento de imagem para a detecção dos lábios na região facial

e a utilização de medidas dos lábios durante o processo de leitura labial. Os fonemas utilizados no trabalho foram retirados da fala utilizando o idioma português do Brasil, constituindo os números do intervalo de zero até nove. As imagens são capturadas por uma câmera de vídeo e em seguida são processadas utilizando operadores morfológicos. A área facial na imagem (Figura 3) é processada (A), e tendo em vista que a área labial é necessária para o algoritmo criado por Silveira, Facon e Borges (2003), é feita a segmentação e parte-se do pressuposto que a maior área segmentada é a área labial do locutor (B). Para o reconhecimento dos fonemas, a representação dos visemas é capturada em vídeo e cada visema tem as medidas labiais referentes à largura e altura armazenada. Em seguida é feita a busca por vizinho mais próximo utilizando a distância euclidiana entre os valores armazenados, classificando assim cada visema em relação ao fonema representado.

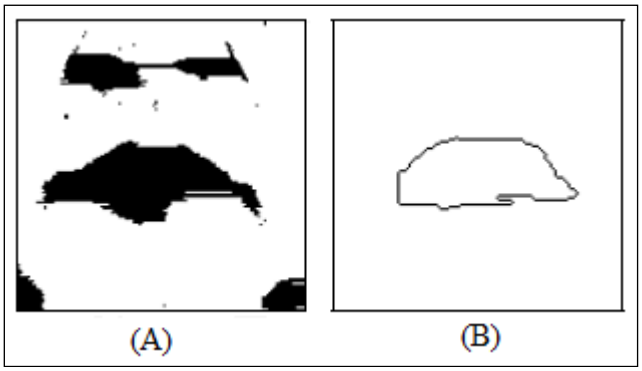

Fonte: Silveira, Facon e Borges (2003).

Figura 3 - Resultados durante a segmentação dos lábios na imagem da face

No terceiro trabalho, apresentado por Hojo e Hamada (2009), propôs-se a utilização de pontos de interesse para a classificação de um grupo de fonemas, constituindo as cinco vogais no idioma Japonês. As imagens do locutor são obtidas através de uma câmera de vídeo, sendo que tanto o dispositivo de captura quanto o locutor permanecem estáticos durante a gravação das imagens e o foco da câmera é a área delimitada pelos lábios. Durante a execução de fonemas, as imagens em vídeo são analisadas a partir de uma técnica que atribui pontos de interesse nas imagens que constituem a sequência de imagens do visema, e é feita uma análise da localização destes pontos no decorrer da execução do visema. A atribuição destes pontos é invariável a alteração de luz. Neste trabalho obteve-se um percentual de detecção de 66% em relação aos fonemas analisados.

O Quadro 1 mostra de forma resumida as principais características dos trabalhos correlatos apresentados.

características / trabalhos relacionados	Shaikh et al.	Hojo e Hamada	Silveira, Facon e

	(2010)	(2009)	Borges (2003)
invariável a luminância	-	X	-
vídeo estático	X	X	X
área de captura	Lábios	Lábios	Face
detecção	-	-	Lábios
técnica de captura do movimento labial	Fluxo óptico	Pontos de interesse	Largura, altura e duas alturas intermediárias
técnica de classificação	Máquinas de vetores de suporte	Pontos de interesse	Vizinho mais próximo
percentual de detecção	95,9%	66%	35%
idioma	Inglês	Japonês	Português
fonemas analisados	Vogais e consoantes	Vogais	Numerais de 0 a 9

Quadro 1 - Características dos trabalhos correlatos

No Quadro 1 as informações foram dispostas em colunas, representando na vertical os trabalhos analisados e as linhas apresentam as características de cada sistema, indicando semelhanças e/ou diferenças.

Também a partir do Quadro 1 é possível observar que a utilização de um ambiente extremamente controlado colabora na maximização dos resultados, tendo em vista que colabora na obtenção de imagens com maior qualidade no que diz respeito às características a serem extraídas.

Pode-se observar também que técnicas que fornecem maior quantidade de dados em relação ao movimento labial, como a técnica utilizada por Shaikh et al. (2010), resulta em maior percentual de detecção dos fonemas analisados.

3 DESENVOLVIMENTO DO PROTÓTIPO

Neste capítulo são abordadas as etapas envolvidas no desenvolvimento do protótipo proposto. São apresentados os principais requisitos, a especificação, a implementação e, por fim, serão apresentados os resultados e discussões.

3.1 REQUISITOS PRINCIPAIS DO PROBLEMA A SER TRABALHADO

O protótipo implementado deverá:

e) permitir o armazenamento de vídeos em um banco de dados. Os vídeos devem conter um locutor efetuando a fala de algum fonema (Requisito Funcional – RF);
f) permitir a especificação do texto falado nos vídeos armazenados no banco de dados do protótipo (RF);
g) tratar as imagens para obter a região delimitada pela boca (RF);
h) interpretar a sequência de imagens durante a execução de um visema a fim de definir os possíveis fonemas equivalentes (RF);
i) ser implementado utilizando como ambiente de desenvolvimento a ferramenta Eclipse e a linguagem de programação C++ (Requisito Não-Funcional – RNF);
j) utilizar como biblioteca de apoio a OpenCV para manipular e aplicar técnicas de processamento de imagem (RNF).

3.2 ESPECIFICAÇÃO

A especificação do protótipo apresentado neste trabalho foi feita utilizando a ferramenta Enterprise Architect versão 7.5. Através desta ferramenta foram desenvolvidos diagramas de caso de uso e de classes, que fazem parte da linguagem *Unified Modeling Language* (UML). Estes diagramas serão apresentados nas próximas seções.

3.2.1 Casos de uso

Nesta seção são descritos os casos de uso do protótipo, conforme apresentados na Figura 4. Foi identificado um ator relevante que interage com o protótipo, denominado `Usuário`.

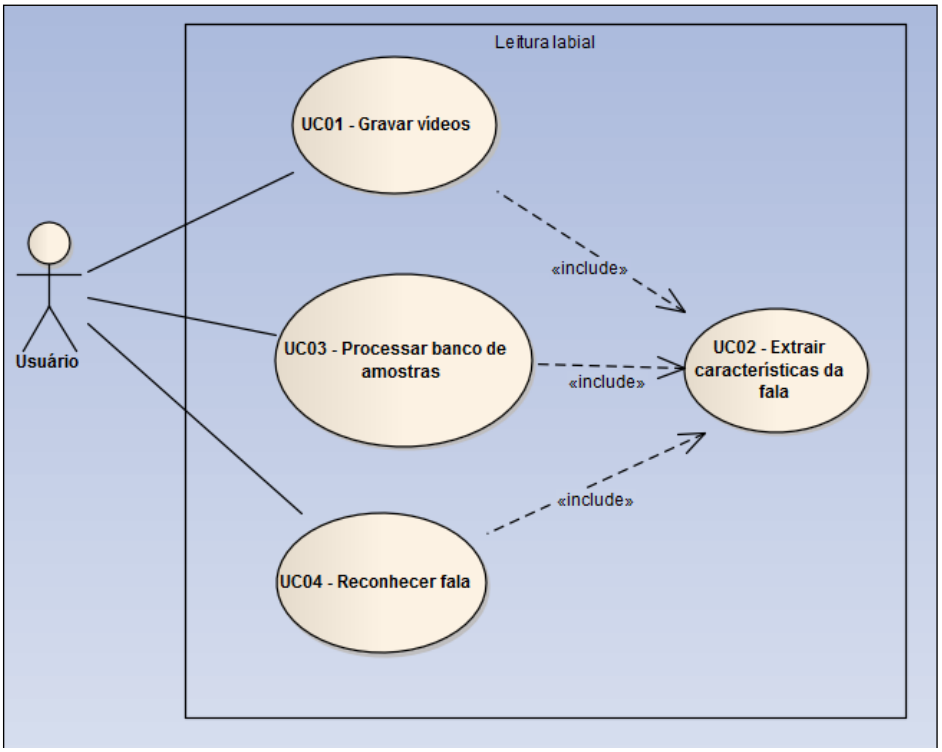

Figura 4 - Diagrama de casos de uso

Os requisitos foram agrupados em quatro casos de uso, que serão descritos em detalhes nas próximas seções.

3.2.1.1 Gravar vídeos da fala

O caso de uso de gravar vídeos é uma das primeiras etapas na utilização do protótipo de leitura labial e é descrito no Quadro 2.

Número	01
Caso de uso	Gravar vídeos da fala

Descrição	Caso de uso da funcionalidade que permite gravar vídeos utilizados pelo protótipo durante o reconhecimento da fala.
Ator	`Usuário`
Pré-condições	Possuir uma câmera de vídeo conectada ao computador e o protótipo de leitura labial aberto.
Pós-condições	Vídeos da fala armazenados
Cenário principal	1. O `Usuário` digita o número um na entrada padrão do protótipo equivalente a opção `Gravar vídeos`; 2. O protótipo solicita o texto a ser falado; 3. O `Usuário` informa o texto a ser falado; 4. O protótipo apresenta a imagem capturada da câmera de vídeo juntamente com o contorno extraídos dos lábios; 5. O `Usuário` seleciona a área dos lábios; 6. O `Usuário` ajusta os parâmetros para extração do contorno labial; 7. O protótipo chama o caso de uso `UC02 - Extrair características da fala` e exibe o contorno labial para o `Usuário`; 8. O `Usuário` identifica que o ambiente é propício para extração do contorno labial; 9. O `Usuário` clica no controle de tela intitulado `Rec`; 10. O protótipo exibe a mensagem `Aguarde` enquanto aguarda a estabilização da velocidade de captura de vídeo; 11. O protótipo exibe a mensagem `OK` quando estabiliza a velocidade de captura de vídeo; 12. O `Usuário` efetua a fala do texto a ser gravado; 13. O `Usuário` clica no controle de tela intitulado `Rec` e finaliza a gravação; 14. O `Usuário` pressiona qualquer tecla para interromper a gravação de vídeo; 15. O protótipo apresenta o menu inicial novamente.
Cenário alternativo	No passo 13 o `Usuário` pode decidir gravar mais vídeos e então o cenário retorna para o passo 9.

Quadro 2 - Caso de uso UC01

3.2.1.2 Extrair características da fala

O caso de uso de extração de características da fala é utilizado pelos casos de uso principais e não é ativado diretamente pelo usuário. Detalhes do cenário deste caso de uso podem ser vistos no Quadro 3.

Número	02
Caso de uso	Extrair características da fala

Descrição	Caso de uso da funcionalidade que extrai as características a serem utilizadas para o reconhecimento da fala.
Ator	`Usuário`
Pré-condições	Existirem vídeos gravados pelo `Usuário` no caso de uso UC01 e o protótipo de leitura labial aberto.
Pós-condições	As imagens serem processadas e alteradas para exibirem o contorno de acordo com os parâmetros especificados pelo usuário.
Cenário principal	1. O protótipo lê as imagens de vídeo e os parâmetros correspondentes; 2. O protótipo carrega em memória uma referência para um vídeo; 3. O protótipo carrega duas imagens do vídeo para a memória; 4. Para cada imagem o protótipo extrai a região de interesse dos lábios de acordo com os parâmetros informados pelo `Usuário`; 5. Para cada imagem o protótipo aplica operações de processamento de imagem utilizando os parâmetros informados pelo `Usuário` e extrai o contorno labial; 6. Sobre cada imagem o protótipo exibe o contorno labial; 7. Comparando as duas imagens o protótipo salva o percentual de alteração das medidas de largura, altura e altura intermediárias dos lábios; 8. O protótipo repete o passo 3 enquanto houverem imagens no vídeo referenciado; 9. O protótipo repete o passo 2 enquanto houverem vídeos a serem referenciados.

Quadro 3 - Caso de uso UC02

3.2.1.3 Processar banco de amostras

O caso de uso de processamento do banco de amostras é uma das últimas partes do processo de leitura labial. O cenário de utilização deste caso de uso pode ser visualizado no Quadro 4.

Número	03

Caso de uso	Processar banco de amostras
Descrição	Caso de uso da funcionalidade que percorre os vídeos gravados e reajusta os parâmetros de extração das medidas labiais.
Ator	`Usuário`
Pré-condições	Existirem vídeos gravados pelo `Usuário` no caso de uso UC01 e o protótipo de leitura labial aberto.
Pós-condições	Os vídeos gravados possuírem um arquivo de configurações contendo os parâmetros escolhidos pelo usuário para a extração do contorno labial.
Cenário principal	1. O `Usuário` digita o número dois na entrada padrão do protótipo equivalente a opção `Processar Amostras`; 2. O protótipo apresenta um menu com as opções para processamento de amostras; 3. O `Usuário` informa o número um que corresponde à opção `Processar apenas os novos`; 4. O protótipo lê as imagens de vídeo e os parâmetros correspondentes somente para arquivos que ainda não foram processados previamente pelo `Usuário`; 5. O protótipo carrega em memória uma referência para um vídeo; 6. O protótipo carrega duas imagens do vídeo para a memória; 7. Para cada imagem o protótipo extrai a região que o `Usuário` selecionou indicando a localização dos lábios; 8. Para cada imagem o protótipo aplica operações de processamento de imagem utilizando os parâmetros informados pelo `Usuário` e extrai o contorno labial; 9. Sobre cada imagem o protótipo exibe o contorno labial; 10. O `Usuário` identifica que o contorno labial está sendo extraído da melhor forma possível utilizando os parâmetros para edição disponibilizados e clica no controle de tela `Good Params;` 11. O protótipo repete o passo 3 enquanto houverem imagens no vídeo referenciado; 12. O protótipo repete o passo 2 enquanto houverem vídeos a serem referenciados.
Cenários alternativos	No passo 10, se o `Usuário` identificar que o contorno pode ser melhorado ele edita os parâmetros disponibilizados através dos controles de tela enquanto o vídeo é exibido repetidamente. No passo 3, o `Usuário` informa o número dois correspondente à opção Informa`r texto dos vídeos processados` e informa o texto, fazendo com que o protótipo carregue somente vídeos com o texto informado, seguindo para o passo 5. No passo 3, o `Usuário` informa o número três correspondente à opção `Informar texto e número do vídeo` e informa os valores, fazendo com que o protótipo carregue somente o vídeo com o texto e número informados, seguindo para o passo 5. No passo 3, o `Usuário` informa o número quatro, correspondente à opção `Processar todos os vídeos`, fazendo com que o protótipo carregue todos os vídeos gravados, seguindo para o passo 5.

Quadro 4 - Caso de uso UC03

3.2.1.4 Reconhecer fala

O caso de uso de reconhecimento de fala é o último no processo de utilização do protótipo. Uma descrição detalhada da utilização pode ser vista no Quadro 5.

Número	04
Caso de uso	Reconhecer fala
Descrição	Caso de uso de reconhecimento de fala, o qual o `Usuário` escolhe um vídeo gravado e executa o reconhecimento do vídeo selecionado.
Ator	`Usuário`
Pré-condições	Existirem vídeos gravados pelo `Usuário` no caso de uso UC01 e o protótipo de leitura labial aberto.
Pós-condições	O texto estimado pelo protótipo de reconhecimento de fala relativo ao vídeo selecionado.
Cenário principal	1. O `Usuário` digita o número três na entrada padrão do protótipo equivalente a opção `Reconhecer fala`; 2. O protótipo apresenta o menu com as opção correspondentes; 3. O `Usuário` informa o número um correspondente à opção `Escolher o texto/vídeo`; 4. O `Usuário` informa o texto e número do vídeo que deseja utilizar para reconhecer a fala; 5. O protótipo localiza os vídeos que atendem o filtro informado pelo `Usuário`; 6. Para cada vídeo o protótipo carrega uma referência em memória; 7. O protótipo carrega todos os vídeos não utilizados e utiliza como fonte de pesquisa para o reconhecimento; 8. O protótipo percorre sequencialmente as imagens do vídeo selecionado; 9. O protótipo carrega duas imagens do vídeo e extrai as informações do contorno labial invocando o caso de uso `UC02 – Extrair características da fala`; 10. O protótipo localiza o texto provável falado no vídeo informado de acordo com as características extraídas; 11. O protótipo exibe para o `Usuário` a segunda imagem carregada e indica na imagem o contorno extraído; 12. O protótipo exibe para o `Usuário` os textos mais prováveis até a segunda imagem extraída; 13. O protótipo volta ao passo 7 enquanto houverem imagens para o vídeo selecionado; 14. O protótipo volta ao passo 6 enquanto houverem vídeos a serem reconhecidos.
Cenário alternativo	No passo 3, o `Usuário` informa o número dois correspondente à opção `Reconhecer todos os vídeos`, e o sistema carrega todos os vídeos existentes no banco de amostras, seguindo para o passo 6.

Quadro 5 - Caso de uso UC04

3.2.2 Diagrama de classes

Nesta seção são descritos os relacionamentos e estrutura das classes desenvolvidas na implementação deste protótipo. Na Figura 5 são demonstrados os agrupamentos lógicos das classes implementadas.

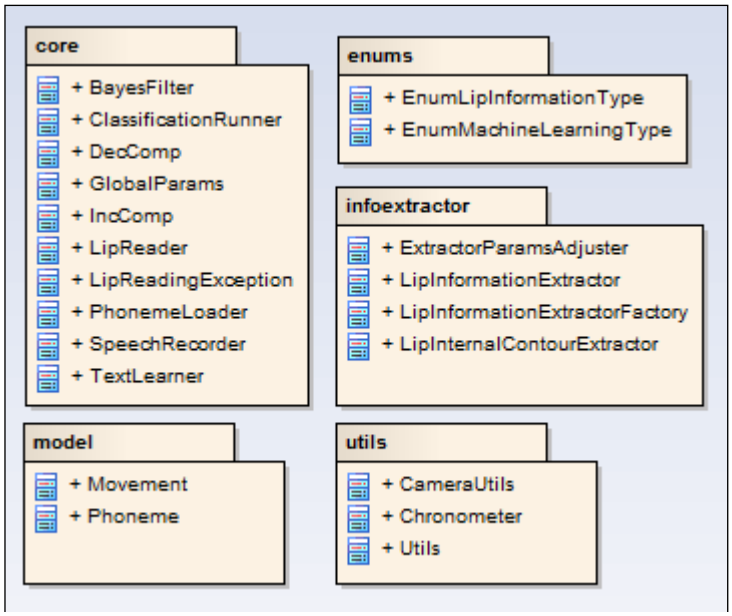

Figura 5 - Diagrama de pacotes do protótipo de leitura labial

3.2.2.1 Pacote `model`

O pacote `model` contém as classes que representam as abstrações dos conceitos referentes ao domínio da aplicação, sendo este a fala, e pode ser observado na Figura 6.

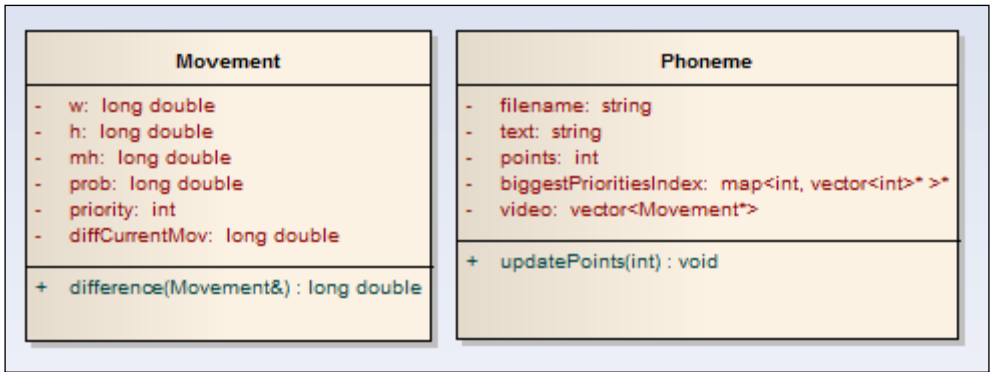

Figura 6 - Pacote `model`

A classe `Movement` armazena as informações relativas à transição de uma imagem para outra durante um vídeo que contém a fala. Os atributos `w`, `h` e `mh` representam respectivamente

o percentual de alteração de largura, altura e altura intermediária do contorno dos lábios entre uma imagem e outra de um vídeo que contém uma pessoa efetuando a fala. O atributo `diffCurrentMov` representa a diferença entre o movimento mais recente que foi lido da câmera de vídeo. O atributo `prob` representa a probabilidade que o movimento tem de ser igual ao movimento que foi capturado durante o reconhecimento de fala, enquanto o atributo `priority` representa o grau de importância que este movimento tem em relação ao atributo `prob` e à quantidade de amostras utilizadas durante a fase de treinamento. A principal operação efetuada pela classe `Movement` é chamada de `difference`, e calcula a diferença entre o movimento atual e um movimento informado como parâmetro através dos atributos de largura, altura e altura intermediária.

A classe `Phoneme` representa um ou vários fonemas através de um conjunto de referências para classes do tipo `Movement`. Ela pode através do atributo `filename` armazenar o nome do arquivo de vídeo que foi utilizado para obter as informações do movimento, assim como o conteúdo textual do qual o fonema equivale utilizando o atributo `text`. Outro atributo importante é o valor inteiro `points`, que representa um valor calculado durante a etapa de reconhecimento da fala, e indica o peso que o fonema tem no resultado final da classificação do conteúdo falado. A principal operação efetuada pela classe `Phoneme` é calcular a quantidade de pontos que o fonema possui, utilizando o atributo `priority` de cada movimento constituinte.

3.2.2.2 Pacote `utils`

O pacote `utils` contém as classes utilitárias utilizadas no protótipo, e é representado na Figura 7.

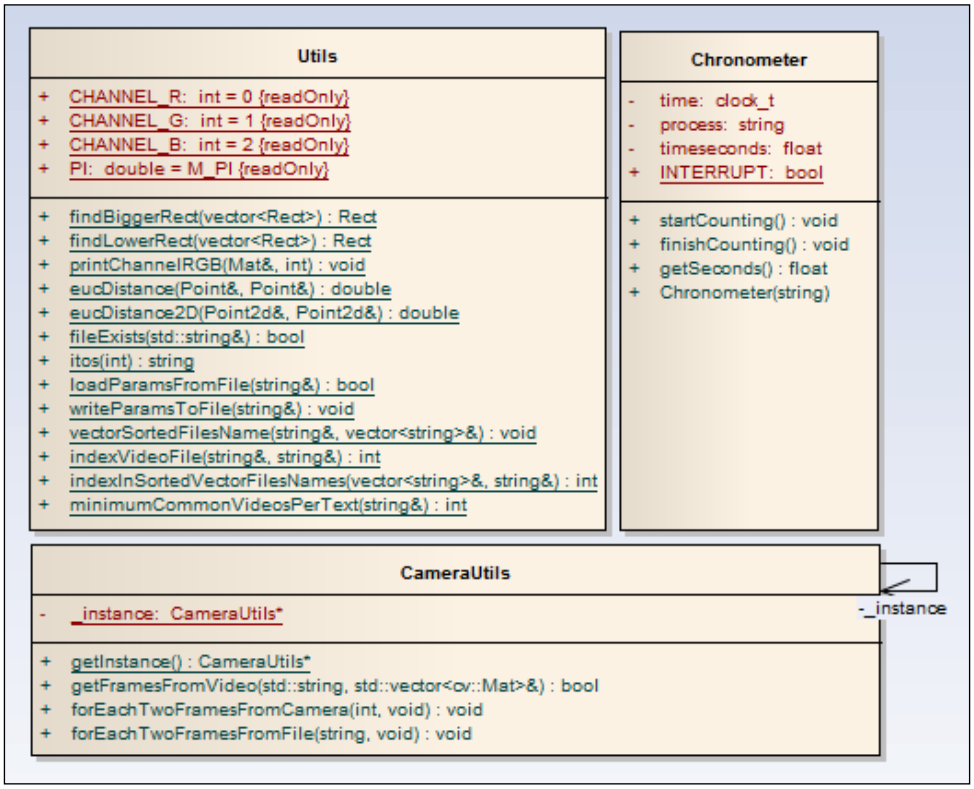

Figura 7 - Pacote `utils`

A classe `Chronometer` é utilizada para cronometrar o tempo de execução das funções do protótipo. Ela possui uma referência para o nome do processo sendo cronometrado através do atributo `process`. O método `startCounting` armazena o tempo inicial, enquanto o método `finishCounting` calcula o tempo decorrido e exibe na saída padrão da aplicação. A variável estática booleana `INTERRUPT` é utilizada para interromper a atividade da classe fazendo com que os métodos `startCounting` e `finishCounting` não efetuem nenhuma operação.

A classe `Utils` contém métodos utilitários gerais, sendo eles:

a) `findBiggerRect`: dada uma lista de retângulos retorna aquele que possuir a maior área;

b) `findLowerRect`: dada uma lista de retângulos retorna aquele que estiver na parte mais inferior da imagem;

c) `printChannelRGB`: data uma imagem e um valor de constante inteira (`CHANNEL_R`, `CHANNEL_G`, `CHANNGEL_B`) exibe os valores do modelo de cores RGB para cada pixel da imagem;

d) `eucDistance` e `eucDistance2D`: distância euclidiana entre dois pontos inteiros ou decimais;

e) `fileExists`: verifica se um arquivo com o endereço informado existe;

f) `itos`: converte um valor textual para numérico;

g) `loadParamsFromFile`: carrega para memória os parâmetros necessários para extração das características do contorno labial;

h) `writeParamsToFile`: escreve em disco rígido um arquivo contendo os parâmetros necessários para extração das características do contorno labial;

i) `vectorSortedFilesName`: dado um diretório em disco rígido, carrega os nomes dos arquivos de vídeo existentes e retorna uma lista ordenada para o segundo parâmetro informado;

j) `indexVideoFile`: retorna a posição de um arquivo em uma lista ordenada pelo nome dos arquivos;

k) `indexInSortedVectorFilesNames`: retorna o índice de um nome de arquivos dentro de uma lista de nomes de arquivos;

l) `minimumCommonVideosPerText`: dado um diretório onde os arquivos de vídeos gravados se localizam, retorna a quantidade mínima de vídeos para todos os textos gravados, ou seja, se para um texto houver três vídeos e um segundo texto contém cinco vídeos, o retorno do método seria três.

A classe `CameraUtils` contém métodos utilitários para leitura paginada de vídeos em arquivos (`forEachTwoFramesFromFile`), leitura de imagens da câmera (`forEachTwoFramesFromCamera`) e também para carregar vídeos completos para a memória (`getFramesFromVideo`).

3.2.2.3 Pacote `infoextractor`

O pacote `infoextractor` contém as classes responsáveis por extrair as informações relativas aos movimento dos lábios, conforme apresentado na Figura 8.

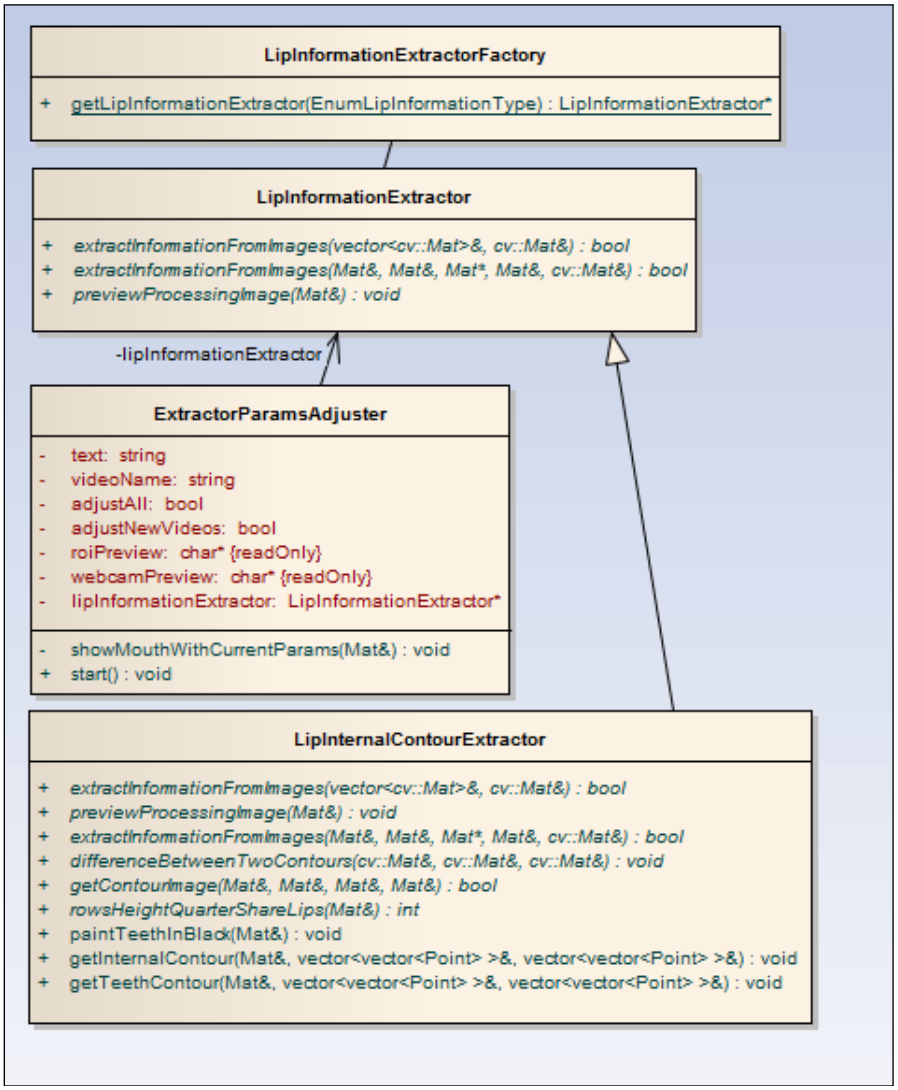

Figura 8 - Pacote `infoextractor`

A classe abstrata `LipInformationExtractor` é responsável por definir o conjunto de atividades que uma classe responsável por extrair medidas dos lábios deve efetuar. Foi modelada com o objetivo de permitir diferentes implementações da extração de dados dos lábios ou do movimento.

A classe `LipInformationExtractorFactory` é responsável por retornar uma instância de classe que implemente as funções de extração de informações labiais.

A classe `LipInternalContourExtractor` implementa os métodos definidos na classe `LipInformationExtractor` utilizando alguns métodos auxiliares para atingir o objetivo de extração do contorno interno dos lábios. Os métodos `extractInformationFromImages` são responsáveis por retornar os dados referentes à variação das medidas dos lábios entre uma imagem e outra. Os métodos auxiliares desempenham as seguintes funções:

a) `getContourImage`: efetua operações na imagem a fim de retornar uma imagem com

o contorno estabelecido;

b) `paintTeethInBlack`: pinta a área da boca onde houver dentes;

c) `getInternalContour`: retorna todos os contorno que não estão atingindo as bordas da imagem da boca;

d) `getTeehContour`: dada uma lista de pontos que representam contorno obtidos a partir da imagem labial, determina quais deles estão dentro do contorno labial e retorna-os;

e) `differenceBetweenLips`: dadas duas imagem com contorno labial, compara os tamanhos e retorna o percentual de alteração da largura, altura e altura intermediária dos lábios;

f) `rowsHeightQuarterShareLips`: retorna a altura intermediária dos lábios. Essa medida se encontra no meio da extrema lateral dos lábios até o centro dos lábios.

Além disso, a classe `LipInternalContourExtractor` também implementa o método `previewProcessingImage`, que é utilizado para desenhar um contorno em uma imagem informada. Este método é invocado durante a gravação dos vídeos para exibir a aplicação dos parâmetros de extração do contorno informados pelo usuário.

3.2.2.4 Pacote `enum`

O pacote `enum` representa enumerações com tipos de determinadas operações do protótipo. Suas classes estão representadas na Figura 9.

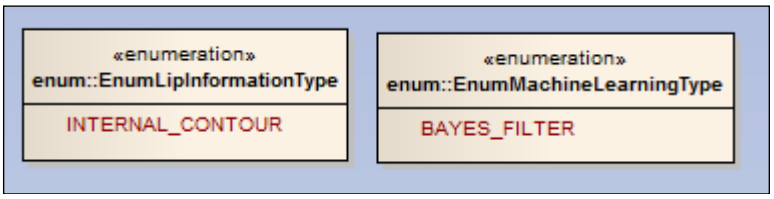

Figura 9 - Pacote `enum`

A enumeração `EnumLipInformationType` indetifica o tipo de informação extraído durante a leitura labial, enquanto a enumeração `EnumMachineLearningType` indica o tipo de inteligência artificial a ser utilizado na fase de reconhecimento da fala. Ambas as enumerações foram criadas visando implementações futuras de outros métodos de extração de características da fala e classificação.

3.2.2.5 Pacote `core`

O pacote `core` contém as classes principais para o reconhecimento da fala implementado no protótipo. Suas classes podem ser visualizadas na Figura 10.

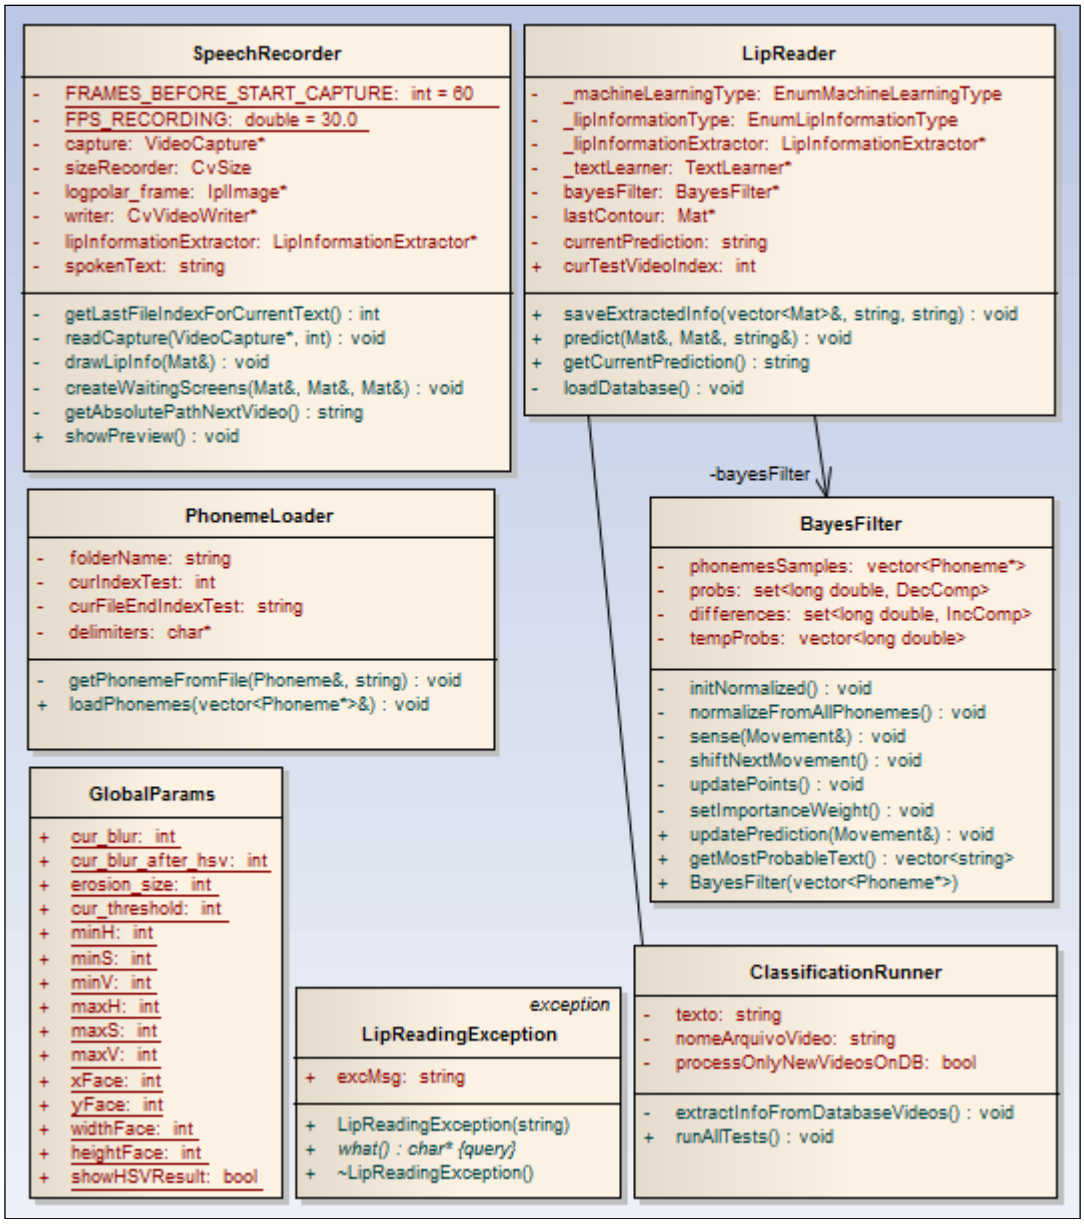

Figura 10 - Pacote `core`

A classe `SpeechRecorder` é responsável por implementar os métodos que desempenham as funções de gravação das imagens de vídeo da fala. Os atributos `capture`, `sizeRecorder`, `logpolar_frame` e `writer` são utilizados com a biblioteca OpenCV para a captura das imagens da câmera. O método `showPreview` é invocado inicialmente para a exibição das imagens sendo capturadas da câmera de vídeo. O método `readCapture` inicia o processo de leitura da câmera e exibição das imagens do contorno labial através do método

drawLifInfo. O método createWaitingScreens armazena em memória as telas criadas dinamicamente para solicitar a espera do usuário ao iniciar a gravação de vídeos da fala. O método getLastIndexFileCurrentText retorna a quantidade atual de vídeos com o texto sendo gravado, enquanto o método getAbsolutePathNextVideo obtém um endereço para o arquivo a ser criado e onde será armazenado o vídeo a ser gravado. A constante FRAMES_BEFORE_START_CAPTURE representa a quantidade de imagens que o sistema captura da câmera antes de iniciar a gravação dos vídeos, a fim de estabilizar a velocidade de captura das imagens, enquanto a constante FPS_RECORDING indica a quantidade de imagens por segundo que a gravação pela biblioteca OpenCV deve utilizar ao criar o arquivo de vídeo. O atributo lipInformationExtractor é responsável por extrair o contorno e exibir ao usuário, enquanto o atributo spokenText equivale ao texto informado pelo usuário ao iniciar a gravação dos vídeos.

A classe GlobalParams é utilizada durante a fase de extração de características de determinado vídeo e contém os valores de parâmetros que servem para efetuar funções de computação gráfica e extrair o contorno labial. Estes valores são obtidos durante a fase de treino das amostras.

A classe LipReader é responsável por gerenciar a leitura labial. O método predict é responsável por obter a classificação do fonema atual quando fornecidas as imagens por parâmetros. O método saveExtractedInfo armazena os dados dos movimentos dos lábios em determinado conjunto de imagens de um vídeo e salva em arquivos de texto. O método loadDatabase carrega os dados dos movimentos labiais dos vídeos que serão utilizados para a busca e classificação dos vídeos a serem reconhecidos.

A classe PhonemeLoader serve para carregar arquivos que contém as informações do movimento labial que foram extraídas no método saveExtractedInfo na classe LipReader. Ela foi criada para que reduzisse o tempo de execução durante os testes, podendo assim evitar o carregamento das informações do banco de amostras quando estas já tiveram suas informações extraídas para o algoritmo de busca.

A implementação do algoritmo de filtro de Bayes é feito pela classe BayesFilter. Para isso ela mantém referência para todos os fonemas que foram carregados durante a fase de treinamento das amostras. O método updatePrediction é responsável por atualizar todas as probabilidades dado algum movimento dos lábios observado, e faz uso dos métodos sense, shiftNextMovement, setImportanceWeight e updatePoints. Estes métodos tem a seguinte funcionalidade:

a) `sense`: é responsável por receber os dados do movimento dos lábios de alguma observação. A partir disso atualiza a distribuição probabilística, atualizando assim para cada movimento das amostras treinadas a probabilidade de ser o mesmo movimento observado;
b) `shiftNextMovement`: efetua a atualização da distribuição probabilística nas amostras observadas dado o movimento dos lábios observados;
c) `setImportanceWeight`: dadas as probabilidades resultantes nas amostras treinadas, verifica quais as maiores probabilidades e atribui determinada prioridade para cada movimento;
d) `updatePoints`: para cada fonema atualiza os pontos obtidos comparando as prioridades já existentes com as novas prioridades obtidas, e incrementa os pontos quando as prioridades se mantiveram lineares.

Por fim a classe `ClassificationRunner` implementa a execução do reconhecimento em um ou vários vídeos e é responsável por exibir os resultados da classificação.

3.3 IMPLEMENTAÇÃO

A seguir são mostradas as técnicas e ferramentas utilizadas no desenvolvimento do protótipo implementado, bem como descrições detalhadas de rotinas e classes relevantes.

3.3.1 Técnicas e ferramentas utilizadas

Para o desenvolvimento do protótipo foi utilizada a linguagem de programação C++. O desenvolvimento foi efetuado utilizando a ferramenta Eclipse 4.2 e o *plugin* C/C++ *Development Tooling* (CDT). O CDT é um *plugin* que facilita a compilação do código em C/C++ diminuindo o tempo de configuração de projetos e facilitando assim o desenvolvimento nesta linguagem.

Toda a implementação de extração de características do contorno labial foi desenvolvida com a biblioteca OpenCV versão 2.4.1.

O código desenvolvido em C++ fez também grande uso da biblioteca *Standard Template*

Library (STL) tanto nas funcionalidades implementadas com a biblioteca OpenCV quanto no algoritmo de classificação.

3.3.2 Etapas do processamento

O processamento durante o reconhecimento da fala foi divido nesta seção em quatro etapas: aquisição, configuração dos parâmetros, extração do contorno labial e reconhecimento da fala.

A etapa de aquisição trata da captura inicial das imagens e está relacionada com a fase de extração do contorno. Na etapa de configuração dos parâmetros o usuário percorre os vídeos gravados e ajusta os parâmetros necessários para a extração do contorno. Por último, na etapa de reconhecimento da fala, dadas as características extraídas na etapa de extração do contorno labial, é feito então uso da técnica de filtro de Bayes. Essas etapas serão explicadas em detalhes nos próximos tópicos.

3.3.2.1 Aquisição

A primeira etapa denominada aquisição consiste na obtenção das imagens utilizando um dispositivo de entrada, neste protótipo sendo uma câmera de vídeo acoplada ao computador que executa o protótipo.

A etapa de aquisição das imagens foi implementada com a biblioteca OpenCV. Para exemplificar a forma como a API foi utilizada o código é demonstrado no Quadro 6.

No Quadro 6, pode-se encontrar na linha 5 a criação de referência para captura de imagens da câmera, a qual é indicada por um valor numérico de acordo com a quantidade de dispositivos de captura conectados ao computador.

Na linha 11 pode-se observar a instância de objeto responsável por escrever as imagens capturadas da câmera para arquivos em disco.

Por último, na linha 16 a imagem capturada é escrita para o vídeo.

```
1.  void testCaptureFrameFromCamera(){
2.      CvCapture* capture = 0;
3.      double fps = 30.0;
4.      int camId = 0;
5.      capture = cvCaptureFromCAM(camId);
6.      CvSize sizeRecorder = cvSize(
7.          (int)cvGetCaptureProperty( capture,  CV_CAP_PROP_FRAME_WIDTH),
8.          (int)cvGetCaptureProperty( capture,
CV_CAP_PROP_FRAME_HEIGHT));
9.      CvVideoWriter *writer;
10.     string fileName = "C:/codeCaptureVideo.avi";
11.     writer = cvCreateVideoWriter(fileName.c_str(),
12.                                  CV_FOURCC('D', 'I', 'V', 'X'),
13.                                  fps,
14.                                  sizeRecorder);
15.     IplImage* frame = cvQueryFrame( capture );
16.     cvWriteFrame(writer, frame);
17.     cvReleaseCapture( &capture );
18. }
```

Quadro 6 - Exemplo da utilização da captura para gravação de vídeos

Antes de iniciar o processo de gravação dos vídeos, as imagens são processadas e tem seu contorno extraído e apresentado para o usuário como uma prévia. Isso é feito para que o usuário possa verificar a qualidade do ambiente e se é possível extrair o contorno labial enquanto manipula os parâmetros disponibilizados. Este processo de extração do contorno será explicado a seguir no próximo tópico.

Ao iniciar a gravação de um vídeo, o usuário passa a visualizar uma tela que solicita a espera para o início da fala, nessa etapa o sistema interrompe a exibição da prévia e após um determinado número de imagens capturadas, solicita ao usuário que inicie a fala do texto. Isso é feito para que o processamento das imagens prévias não afete a velocidade de captura do dispositivo de entrada.

3.3.2.2 Configuração dos parâmetros

Durante essa fase, os vídeos que o usuário gravou são apresentados para que o usuário configure os parâmetros necessários para a extração do contorno. Essa fase do processamento foi definida para que facilite a configuração dos parâmetros quando o usuário gravar vídeos da fala com terceiros. Durante essa fase, uma prévia é exibida ao usuário para que ele identifique a qualidade do contorno extraído com os parâmetros existentes, isso é feito exibindo o contorno extraído na imagem que está sendo lida a partir do vídeo previamente gravado. Essa fase de extração do contorno é apresentada em detalhes na próxima seção.

3.3.2.3 Extração do contorno

Durante essa etapa, são utilizados os parâmetros que o usuário informa durante a fase de processamento dos vídeos. São eles:

a) retângulo da região de interesse contendo a área labial;
b) tamanho do núcleo do filtro da mediana na imagem inicial;
c) limites para a limiarização com HSV;
d) tamanho do núcleo do filtro da mediana após a limiarização com HSV;
e) tamanho do padrão utilizado na erosão;
f) limite para limiarização com imagem em tons de cinza.

O primeiro passo na extração do contorno consiste em extrair a região de interesse da imagem original. Essa tarefa é efetuada obtendo-se a região de interesse selecionada pelo usuário, a partir da imagem original capturada da câmera de vídeo. É possível observar na Figura 11, em (a) a imagem de toda a área facial, enquanto (b) representa somente a área de interesse da imagem original.

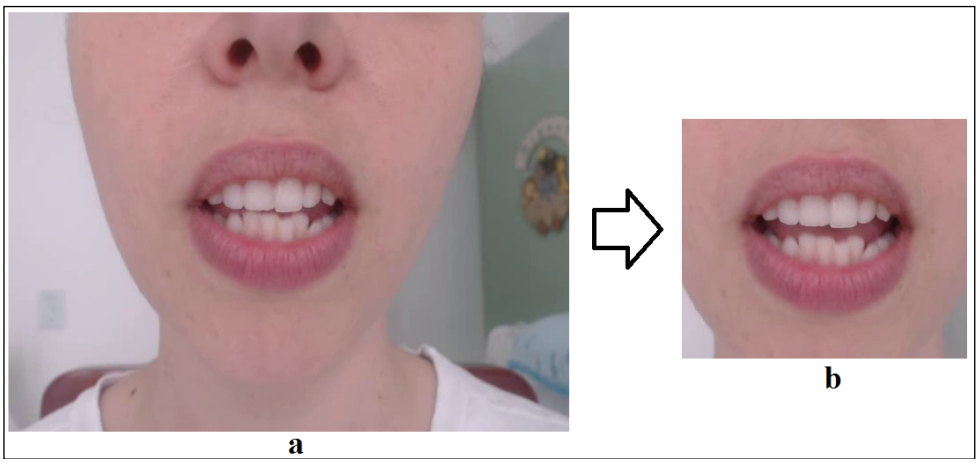

Figura 11 - Imagem original e área de interesse

O próximo passo na extração do contorno interno é a redução de ruído na imagem. Este ruído equivale a minúcias da imagem que podem causar erros na extração do contorno. Podem-se citar como exemplo de ruído as rugas naturais dos lábios. Aplicando o filtro da mediana consegue-se a redução das rugas e a padronização da cor dos lábios.

O filtro da mediana consiste em atribuir um valor para um pixel específico de uma imagem, valor esse que corresponde ao valor médio dos pixels que circundam este local (RUSS, 2011, p. 216).

Para estabelecer quais pixels circundantes de determinado local serão utilizados no cálculo, é estabelecido um formato quadrangular que estabelece quais pixels circundantes serão

utilizados. Conforme a Figura 12, pode observar (a) um padrão composto por 3x3 pixels, em (b) um padrão composto por 5x5 pixels.

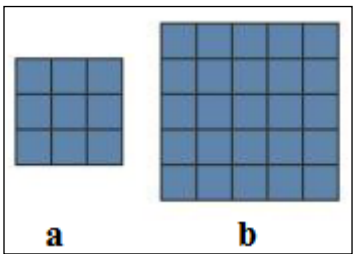

Figura 12 - Formatos e tamanhos do padrão no filtro da mediana

No Quadro 7 é exemplificado o uso da função na biblioteca OpenCV para a aplicação do filtro da mediana, sendo os dois primeiros parâmetros a imagem de origem e destino, e a variável `cur_blur` equivalente ao tamanho do padrão a ser utilizado nos pixels vizinhos, que deve ser um número ímpar.

```
1. medianBlur(imageDest, imageDest, (2*GlobalParams::cur_blur)+1);
```

Quadro 7 - Utilização do filtro da mediana com a OpenCV

O resultado da aplicação do filtro da mediana é apresentado na Figura 13, a qual permite observar uma maior homogeneidade das cores em relação à Figura 11 apresentada anteriormente.

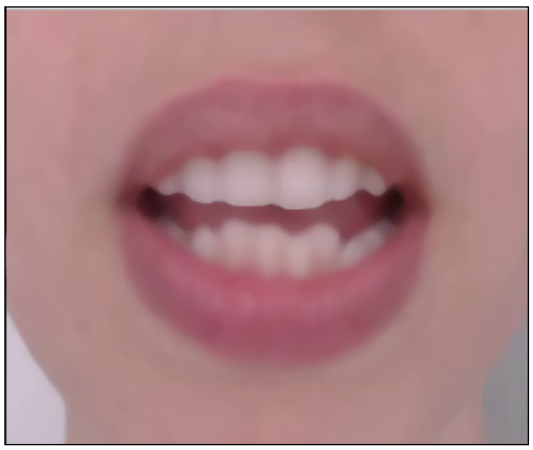

Figura 13 - Aplicação do filtro da mediana na área de interesse

O próximo passo na extração do contorno é a remoção dos possíveis dentes que aparecem na imagem da boca. A implementação nesta etapa consiste na conversão da imagem para a representação de cores HSV e a limiarização da imagem com os valores mínimos e máximos estabelecidos pelo usuário, conforme exibido no Quadro 8. Na linha 1 cria-se variável que é atribuída na linha 2 através do método `cvtColor` que converte a imagem original para o formato HSV. Em seguida percorre-se toda a imagem e as áreas que se encontram no limite HSV determinado pelo usuário são pintadas de preto, enquanto as áreas que não atendem os limites são pintadas de branco. Isso é necessário, pois o processo final exposto adiante utiliza a

limiarização em tons de cinza para obter o contorno interno dos lábios.

```
1.          Mat hsvImage;
2.          cvtColor(copiedOriginalRoi, hsvImage, CV_BGR2HSV);
3.          for (int c = 0; c < hsvImage.cols; c++){
4.              for (int l = 0; l < hsvImage.rows; l++){
5.              Vec3b pixel = hsvImage.at<Vec3b>(l, c);
6.              Vec3b& pixelROI = copiedOriginalRoi.at<Vec3b>(l, c);
7.              if (pixel[0] >= GlobalParams::minH &&
8.                  pixel[0] <= GlobalParams::maxH &&
9.                  pixel[1] >= GlobalParams::minS &&
10.                 pixel[1] <= GlobalParams::maxS &&
11.                 pixel[2] >= GlobalParams::minV &&
12.                 pixel[2] <= GlobalParams::maxV)
13.                 {
14.                         pixelROI[0] = 0;
15.                         pixelROI[1] = 0;
16.                         pixelROI[2] = 0;
17.                 } else {
18.                         pixelROI[0] = 255;
19.                         pixelROI[1] = 255;
20.                         pixelROI[2] = 255;
21.                 }
22.             }
23.         }
```

Quadro 8 - Limiarização HSV

O resultado deste processo é exibido na Figura 14.

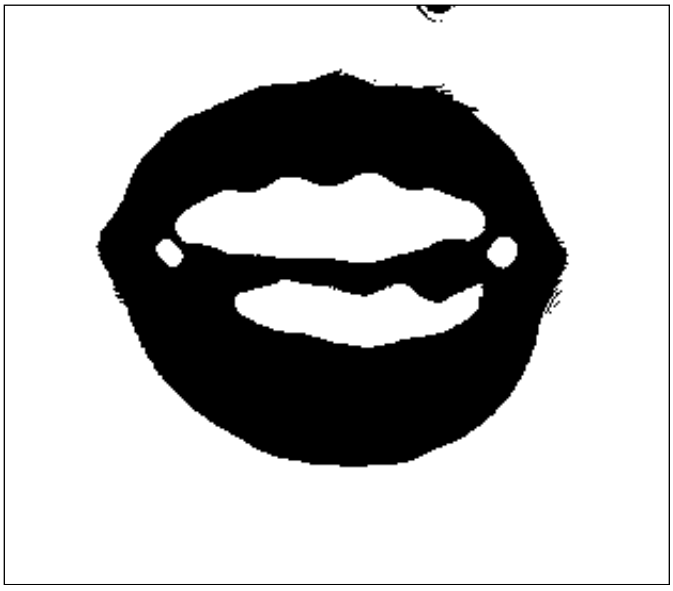

Figura 14 - Aplicação do algoritmo de limiarização com HSV

O próximo passo é aplicar novamente o filtro da mediana na imagem resultante do processo de limiarização com HSV para suavizar os contornos, em seguida é aplicada uma operação de processamento de imagem chamada de erosão. A erosão de imagens binárias consiste basicamente em atribuir o valor de um pixel para o valor considerado como cor de fundo caso algum pixel vizinho contenha este valor de cor de fundo (RUSS, 2011, p. 469). Neste caso, se um pixel com o valor na cor preta estiver com algum pixel vizinho na cor branca,

o pixel terá seu valor alterado para a cor branca. Além disso, é necessário estabelecer, assim como no filtro da mediana, o formato do padrão a ser considerado na leitura dos pixels vizinhos. No Quadro 9 encontra-se o trecho de código relativo à erosão utilizado no protótipo. Conforme pode ser observado no Quadro 9, a linha 1 contém a referência para o formato do padrão a ser utilizado na erosão, sendo este retangular, enquanto na linha 2 é criada variável que representa o tamanho do padrão a ser utilizado na operação, este tamanho depende da variável `erosion_size`, estabelecida pelo usuário durante o processamento dos vídeos gravados.

```
1.     int erosion_type = MORPH_RECT;
2.     Size
size(2*GlobalParams::erosion_size + 1, 2*GlobalParams::erosion_size+1 );
3.     Mat element = getStructuringElement( erosion_type, size);
4.     erode(copiedOriginalRoi, copiedOriginalRoi, element);
```

Quadro 9 - Aplicação da operação de erosão

A aplicação do filtro da mediana pode ser visualizado na Figura 15.

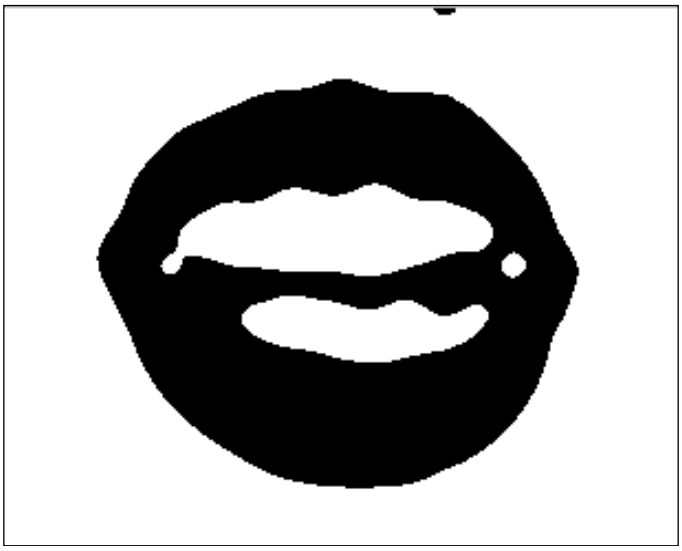

Figura 15 - Aplicação do filtro da mediana após a limiarização com HSV

A aplicação da erosão após o filtro da mediana foi utilizada para eliminar ruídos maiores, conforme exibido na Figura 16. Em muitas situações, como na Figura 15, não há necessidade de utilização dessa operação.

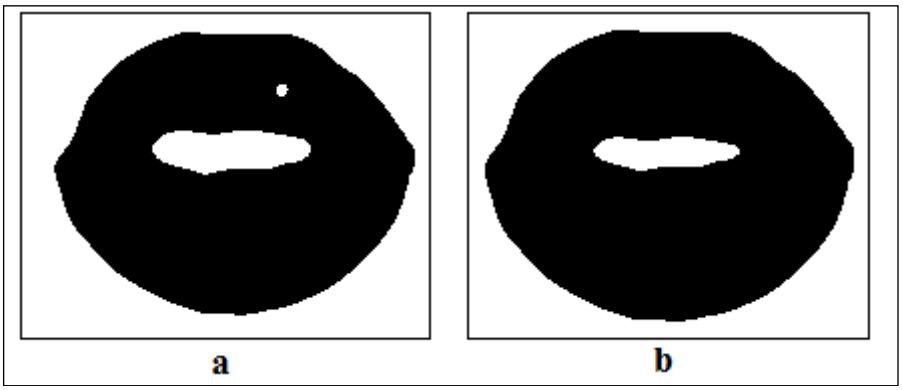

Figura 16 - Exemplo de ruído após a aplicação do filtro da mediana na limiarização HSV

Em seguida, é aplicada na imagem binária resultante, um algoritmo de delimitação dos contornos em imagens deste tipo. Este algoritmo é implementado na biblioteca OpenCV, e a utilização pode ser vista no Quadro 10. A constante informada `CV_RETR_TREE` indica que o resultado contido na lista de contornos representado pela variável `contours` será retornado em uma estrutura hierárquica. Porém esta característica não foi utilizada na implementação deste protótipo. O resultado de sua aplicação pode ser visualizado na Figura 17, que equivale aos contornos da Figura 15.

```
1.    vector<vector<Point> > contours;
2.    findContours(copiedOriginalRoi,
3.                 contours,
4.                 CV_RETR_TREE,
5.                 CV_CHAIN_APPROX_NONE,
6.                 Point(0, 0));
```

Quadro 10 - Utilização da função de busca de contornos

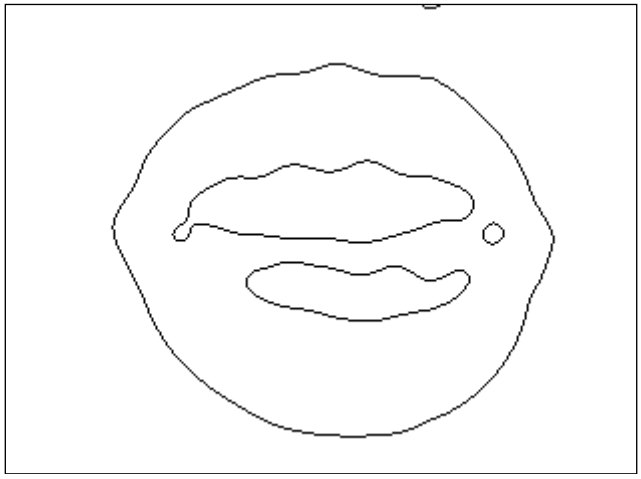

Figura 17 - Contornos detectados pela função `findContours`

O próximo passo executado é a detecção de quais contornos constituem os possíveis dentes na imagem. A implementação deste passo percorre a lista de todos os contornos definindo qual deles é o que possui a maior área e que não tem contado com as bordas da imagem. Em seguida escolhem-se somente os contornos que estão dentro do maior contorno detectado, resultando nos contornos exibidos na Figura 18.

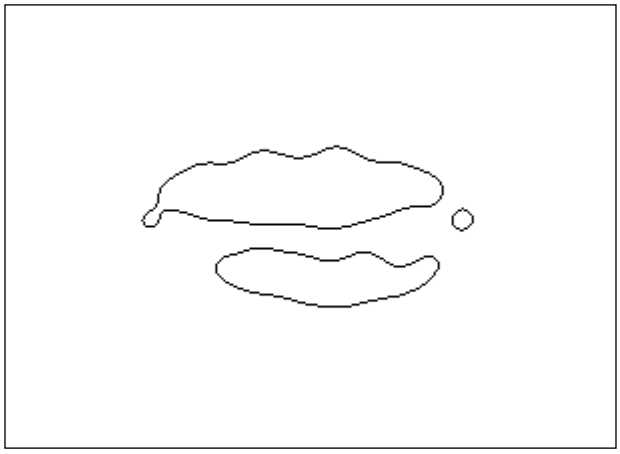

Figura 18 - Contornos equivalentes aos possíveis dentes

O último passo na eliminação dos possíveis dentes que se encontram na imagem da boca consiste na pintura de toda a região dos dentes na cor preta. Tendo em vista que a região entre os dentes da parte superior e inferior da boca não deve afetar o resultado final da extração do contorno interno dos lábios, a implementação do protótipo assume que o polígono convexo formado a partir dos contornos dos possíveis dentes se encontra dentro do contorno interno dos lábios, e deve, portanto, ser eliminado. Dessa forma, foi utilizado o algoritmo implementado pela biblioteca OpenCV para a definição de polígonos convexos a partir de um conjunto de pontos. Conforme exibido no Quadro 11, a função `convexHull` é invocada passando como parâmetro uma estrutura contendo todos os pontos que constituem os contornos exibidos na Figura 18. Em seguida é invocada a função que desenhará na imagem contendo a região de interesse dos lábios, o polígono convexo representando a área dos dentes. Na Figura 19, em (a) pode-se observar os contornos representando os dentes na cor branca, enquanto os contornos que representam o polígono convexo na cor verde. Também em (b) pode-se observar o polígono convexo sendo pintado na imagem contendo a área de interesse.

```
1.    vector<vector<Point> > hull(1);
2.    convexHull(Mat(allPoints), hull[0], false);
3.    drawContours(smallImgROI, hull, -1, Scalar(0,0,0), CV_FILLED, 8);
```

Quadro 11 - Criação do polígono convexo com a OpenCV

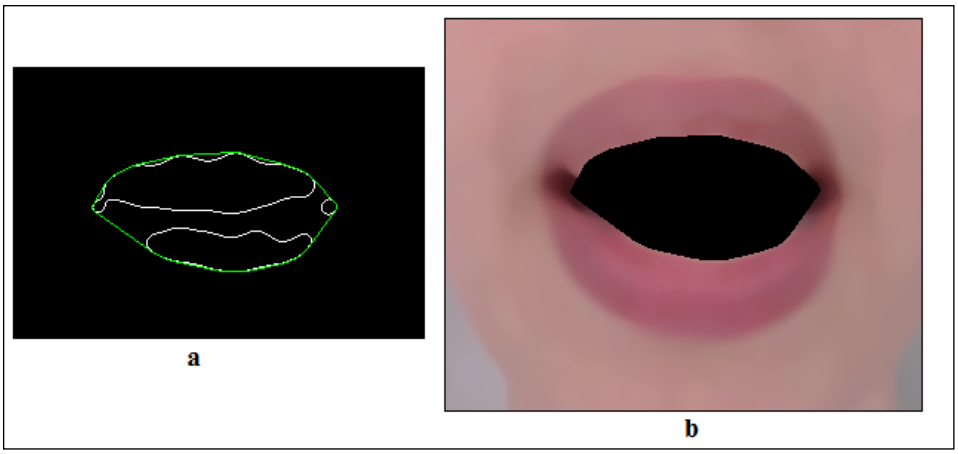

Figura 19 - Utilização do polígono convexo gerado com os dentes

Enfim, a imagem a extração do contorno se dá, aplicando uma limiarização na imagem original que já possui o polígono com a imagem dos dentes pintados. Essa limiarização leva em consideração a área mais escura da imagem. A seguir, é aplicada novamente a função para extração do polígono convexo com base nos contornos extraídos da imagem após a limiarização. Este contorno é o resultado final da etapa de extração do contorno interno dos lábios.

A Figura 20 demonstra as imagens resultantes dessa última fase de extração do contorno. Em (a) a imagem com o polígono convexo pintado é convertido para tons de cinza. Em (b) é exibido o resultado da limiarização em tons de cinza, em (c) é exibido o polígono convexo que representa o contorno da limiarização em (b). Por fim, é exibido em (d) o contorno resultante.

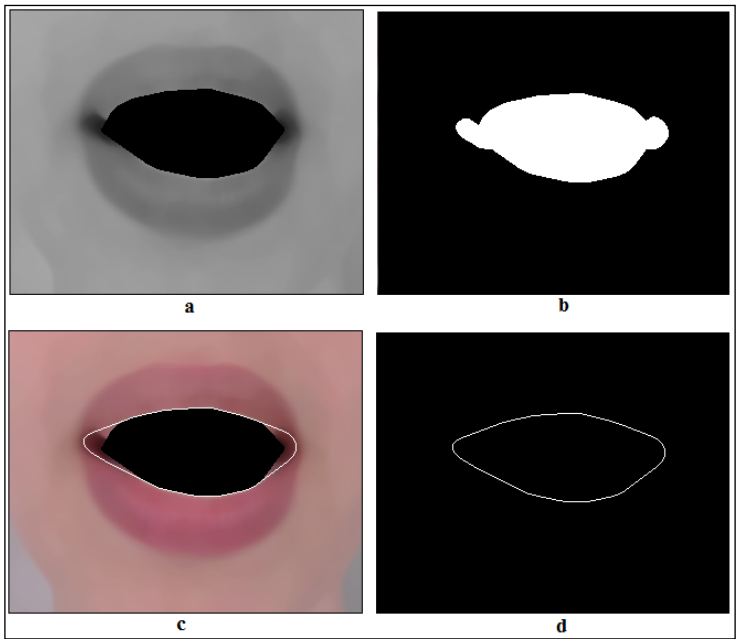

Figura 20 - Processo final de extração do contorno

3.3.2.4 Extração de características do contorno

O processo de extração das características do contorno é efetuado comparando-se o contorno de uma imagem em um tempo `t` com o contorno obtido na imagem em um tempo `t-1`. As características extraídas não se tratam de medidas dos lábios, e sim da relação entre as medidas dos lábios no tempo `t` e as medidas no tempo `t-1`. Ao total, foram utilizadas três medidas dos lábios, conforme apresentadas na Figura 21, são elas a largura (a), a altura (b) e a altura intermediária (c), ou seja, entre o meio dos lábios e uma das laterais horizontais.

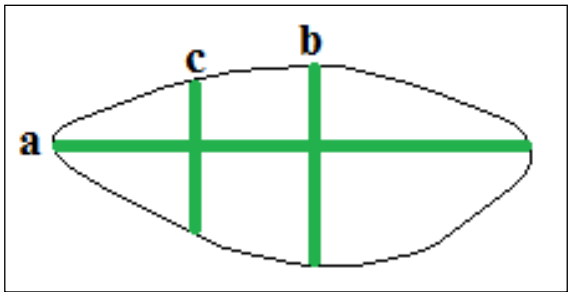

Figura 21 - Medidas utilizadas na extração das características

Dadas as duas imagens e extraídas as medidas de cada uma, os três valores armazenados para a fase de reconhecimento são compostos pela relação dessas medidas entre uma imagem e outra, ou seja, para a medida de largura, por exemplo, é armazenado o quociente da divisão entre a largura da segunda imagem pela largura da primeira imagem. Sendo assim, é possível saber o percentual de aumento ou diminuição de cada medida dos lábios em relação à transição de uma imagem para outra. Essas três informações são utilizadas no algoritmo de reconhecimento da fala apresentado na próxima seção.

3.3.2.5 Reconhecimento da fala

A etapa de reconhecimento da fala foi feita utilizando um algoritmo de baixa complexidade classificado como probabilístico. Este algoritmo possui basicamente quatro etapas:

a) carregar banco de amostras;
b) atribuir uma probabilidade inicial;
c) atualizar as probabilidades dada uma observação;
d) calcular qual a amostra mais compatível.

Na primeira etapa é criado o banco de amostras. O banco de amostras é constituído

conceitualmente de vídeos, sendo que cada vídeo contém uma sequencia de alterações das três medidas extraídas entre o contorno de duas imagens sequenciais da fala. Cada alteração das medidas foi cognominada neste protótipo como movimento. Ou seja, se o vídeo possuísse uma sequencia de três imagens, no banco de amostras este vídeo possuiria dois movimentos, sendo o primeiro equivalente à transição da primeira imagem para a segunda, e o segundo equivalente à transição da segunda imagem para a terceira.

A segunda etapa consiste na atribuição da probabilidade inicial para cada movimento em cada vídeo do banco de amostras. O cálculo da probabilidade inicial consiste em dividir a probabilidade total entre cada evento possível, ou seja, entre todos os movimentos. No Quadro 12 pode-se observar o método responsável por essa inicialização. Nas linhas 6 a 12 calcula-se o tamanho do espaço amostral. Nas linhas 16 a 28 é determinada a probabilidade para cada evento possível do espaço amostral.

```
1.    void BayesFilter::initNormalized(){
2.
3.         int count = 0;
4.         long double normalized = 0.0;
5.
6.         for (vector<Phoneme*>::iterator itePhonemeSample =
7.                   phonemesSamples.begin();
8.              itePhonemeSample != phonemesSamples.end();
9.              itePhonemeSample++){
10.            Phoneme& phoneme = *(*itePhonemeSample);
11.            count += phoneme.getVideo().size();
12.        }
13.
14.        normalized = 1.0 / count;
15.
16.        for (vector<Phoneme*>::iterator itePhonemeSample =
17.                        phonemesSamples.begin();
18.             itePhonemeSample != phonemesSamples.end();
19.             itePhonemeSample++){
20.             Phoneme& phoneme = *(*itePhonemeSample);
21.             for (vector<Movement*>::iterator iteMov =
22.                       phoneme.getVideo().begin();
23.                  iteMov != phoneme.getVideo().end();
24.                  iteMov++){
25.                  Movement* mov = *iteMov;
26.                  mov->setProbability(normalized);
27.             }
28.        }
29.   }
```

Quadro 12 - Atribuição da probabilidade inicial

A próxima etapa consiste na atualização das probabilidades dada uma observação de um movimento. Este processo é repetido a cada leitura de uma nova imagem de um vídeo escolhido para reconhecimento, e é implementado através do método `updatePrediction` apresentado no Quadro 13.

```
1.    void BayesFilter::updatePrediction(Movement& sensedMovement){
2.        sense(sensedMovement);
3.        shiftNextMovement();
4.        setImportanceWeight();
5.        updatePoints();
6.    }
```

Quadro 13 - Processo de atualização das probabilidades

A atualização das probabilidades é feita em conjunto com o armazenamento de uma unidade específica criada para o algoritmo implementado no protótipo, chamada de pontos. Para que os pontos sejam calculados criou-se o conceito de prioridade para determinados eventos do espaço amostral.

A primeira parte do processo, implementada pelo método `sense`, conforme apresentado no Quadro 13, consiste em comparar o evento observado, correspondente à variável `sensedMovement` com cada evento do espaço amostral. Para que a aplicação calcule a probabilidade de cada movimento do espaço amostral ser correspondente ao movimento lido, foram estabelecidas para o algoritmo três probabilidades. Para um número de movimentos do banco de amostras que são fortemente semelhantes, multiplica-se a probabilidade atual de cada um por 0.7, para um segundo grupo cujas semelhanças são menores multiplica-se a probabilidade atual por 0.2, enquanto o restante dos movimentos tem suas probabilidades multiplicadas por 0.1. A quantidade de movimentos para cada grupo de elementos semelhantes foi definido de acordo com testes, não sendo possível ainda o estabelecimento destes valores de forma automática. O próximo passo no método `sense`, é normalizar as probabilidades de cada relação de medidas, tendo em vista que a multiplicação no passo anterior não resulta em uma probabilidade. Isso é feito somando a probabilidade de todos os movimentos e atribuindo a probabilidade para cada um, como sendo o quociente da divisão da probabilidade atual do movimento pela soma das probabilidades de todos os movimentos.

O próximo passo no processo de atualização das probabilidades, é implementado no método `shiftNextMovement`, que consiste em movimentar as probabilidades no espaço amostral para que a maior probabilidade indique a posição a qual a próxima observação estará. Essa parte do algoritmo é responsável por suportar uma pequena variação de velocidade entre as observações e o espaço amostral. A implementação deste método consiste basicamente em recalcular as probabilidades para cada movimento das amostras, utilizando as probabilidades dos movimentos anteriores ou atual. No Quadro 14 observa-se o cálculo da probabilidade de um movimento qualquer. Na linha 2, a probabilidade é calculada obtendo-se a probabilidade de três movimentos, o movimento anterior (`previousMovement`), o movimento antes do anterior (`beforePreviousMovement`) e o movimento atual (`curMov`).

Os valores para PROB_FORWARD, PROB_DOUBLE_FORWARD e PROB_STAY, são equivalentes, respectivamente a 0.8, 0.1 e 0.1, e equivalem respectivamente à probabilidade de uma leitura em vídeo seguir um padrão que se encontra sequencialmente no banco de amostras, variando de um movimento para outro, de dois em dois movimentos, ou que a leitura de um movimento da câmera esteja com velocidade superior à de uma amostra no banco.

```
1.    long double
2.    prob = (PROB_FORWARD * previousMovement->getProbability());
3.    prob += (PROB_DOUBLE_FORWARD * beforePreviousMovement-
>getProbability());
4.    prob += (PROB_STAY * curMov->getProbability());
```

Quadro 14 - Movimentação das probabilidades no espaço amostral

O penúltimo passo na atualização das probabilidades ocorre no método setImportanceWeight. Este método é semelhante ao método sense, e é responsável por verificar e atribuir prioridade aos movimentos das amostras. Para que essa atividade seja efetuada, são definidos quatro conjuntos de movimentos, sendo estes agrupados de acordo com o nível de semelhança com a observação atual. Os conjuntos com maior semelhança à observação atual recebem a maior prioridade, o segundo conjunto com menor semelhança recebe a segunda maior prioridade e assim sucessivamente para o restante dos grupos. A quantidade de elementos em cada conjunto foi definida experimentalmente, e as proporções em relação ao banco de amostras não foram observadas.

O último passo é a execução do método updatePoints. Este método é responsável por verificar a progressão das prioridades nos movimentos de cada vídeo. Essa atividade é efetuada através da observação da progressão das prioridades durante a observação anterior, em relação às novas prioridades atribuídas na observação atual. Quando as prioridades seguem linearmente dentro dos movimentos de determinada amostra de vídeo, são atribuídos pontos para aquela amostra, enquanto que as prioridades que não progrediram linearmente dentro das amostras, contabilizam pontos negativos.

A última parte no processo de reconhecimento consiste no cálculo da amostra que mais se assemelha ao texto falado na observação. Essa atividade é implementada observando a quantidade de pontos que cada amostra do banco contabilizou, e a amostra que possuir maior quantidade de pontos é a que melhor se assemelha com a observação atual.

3.3.3 Operacionalidade da implementação

Esta seção apresenta a operacionalidade da implementação do ponto de vista do usuário

e foi dividida em três seções de acordo com os casos de uso onde há interação com o usuário.

3.3.3.1 Gravar vídeos

A primeira etapa na utilização do protótipo consiste na gravação dos vídeos. O acesso a esta opção é feito através da entrada padrão do protótipo. Ao abrir o protótipo o usuário digita o número um que equivale a opção de gravação de vídeos e em seguida informa qual o texto a ser falado, conforme pode ser visto na Figura 22.

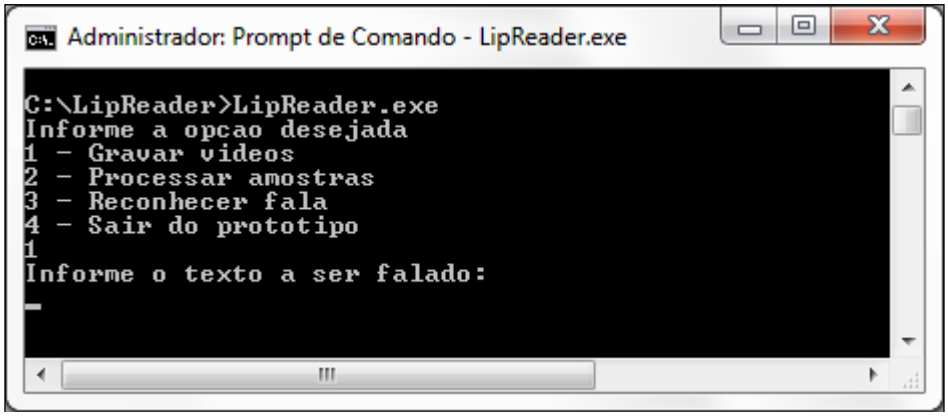

Figura 22 - Menu inicial da aplicação

No próximo passo é apresentada a imagem capturada da câmera de vídeo, exibindo o contorno extraído com os parâmetros atuais, conforme exibido na Figura 23.

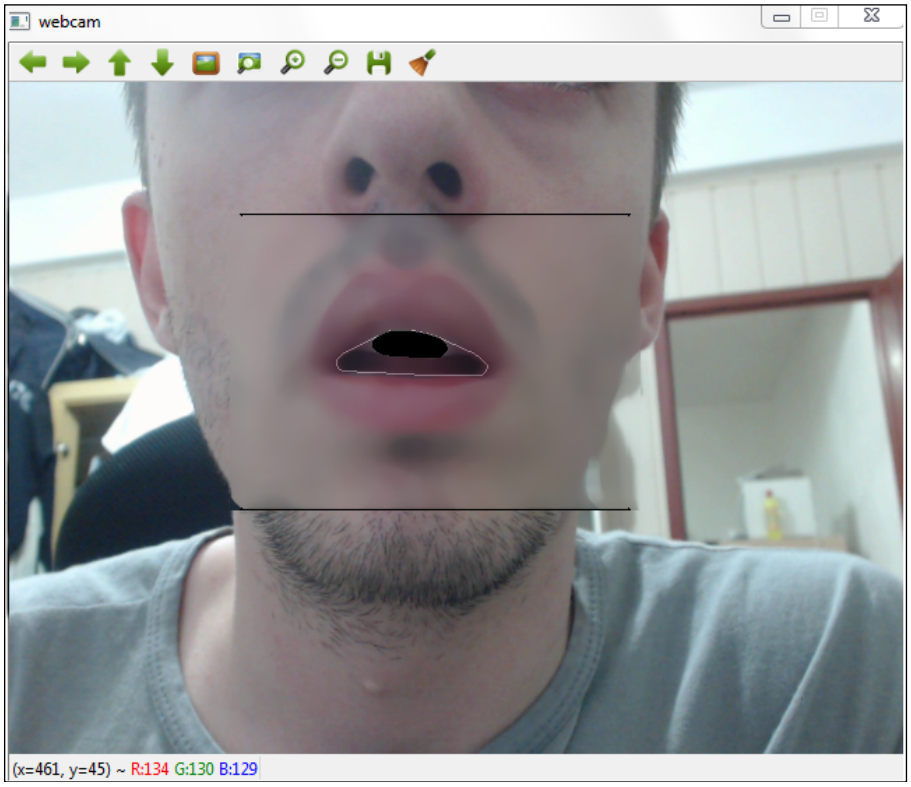

Figura 23 - Contorno apresentado ao usuário para ajuste dos parâmetros

Além disso, conforme pode ser visto na Figura 24, são apresentados para o usuário os controles que permitem manipular os parâmetros e verificar se é possível a extração do contorno no ambiente em que se encontra.

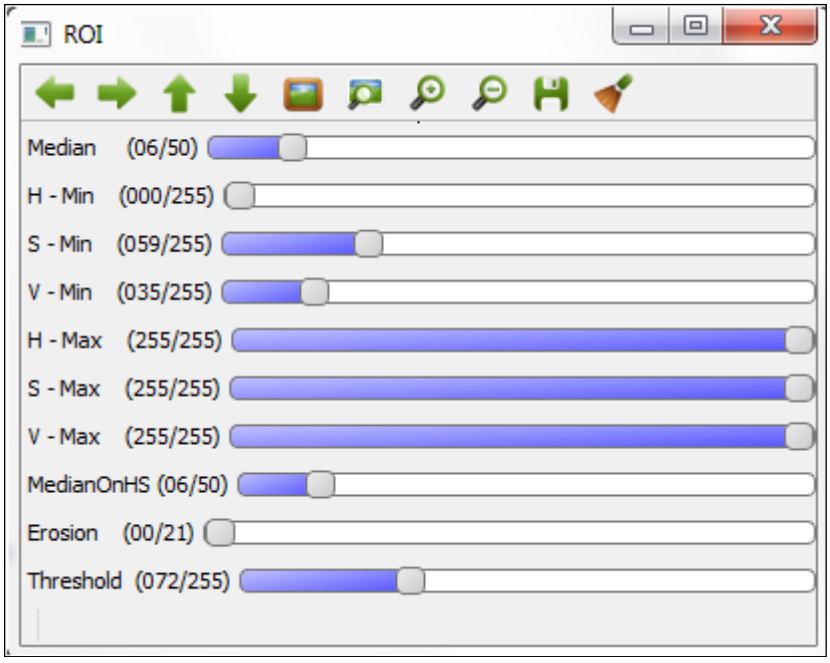

Figura 24 - Parâmetros disponíveis para alteração pelo usuário

Quando o usuário verifica que o contorno é visível e condiz com o contorno real dos lábios, ele inicia a gravação clicando no controle de tela `Rec`, conforme pode ser visualizado na Figura 25. Se o contorno não for condizente com o contorno real, é possível visualizar o

resultado do processo de limiarização e erosão com a imagem no modelo de cores HSV, equivalente ao processo ilustrado na Figura 16, clicando no controle `Show HSV` conforme exibido na Figura 25.

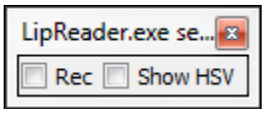

Figura 25 - Controles para a gravação de vídeos

Após pressionar o controle `Rec` apresentado na Figura 26, é apresentada uma tela solicitando a espera (a) enquanto o sistema interrompe a exibição do contorno extraído, e em seguida apresenta uma segunda tela (b), indicando que deve ser iniciada a fala.

Figura 26 - Telas de notificação de espera e início da fala

Ao final do processo a imagem da câmera de vídeo é exibida novamente, e o usuário pode interromper o processo de gravação dos vídeos pressionando qualquer tecla.

3.3.3.2 Processar banco de amostras

Essa fase do processo consiste basicamente em percorrer as imagens gravadas e configurar os parâmetros que foram apresentados na seção de gravação dos vídeos. É possível informar o texto dos vídeos a serem processados, o nome do arquivo de vídeo, processar somente os novos vídeos ou processar todos os vídeos gravados. Para cada vídeo o usuário visualiza o contorno e pode ajustar os parâmetros que maximizem a extração do contorno dos lábios.

3.3.3.3 Reconhecer a fala

Nesta fase do processo, o usuário seleciona a terceira opção do menu inicial, sendo necessário informar o nome do vídeo que foi gravado (ver Figura 27) ou se quer processar todos os vídeos já gravados. Por padrão, os vídeos são armazenados em um diretório cujo endereço é armazenado no arquivo `recording-dir.txt` que se encontra no mesmo local do executável do protótipo.

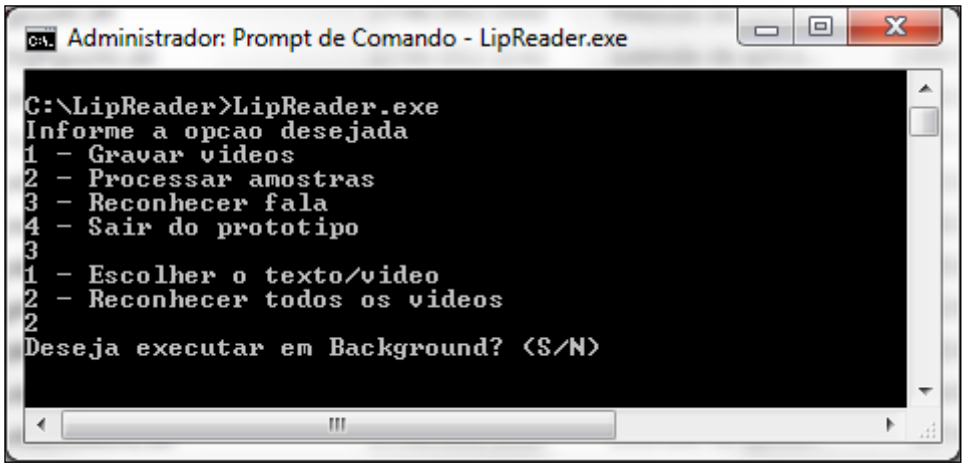

Figura 27 - Menu para reconhecimento de fala

Após informar alguma das opções, o usuário pode escolher se quer visualizar as imagens do vídeo enquanto é feito o reconhecimento ou se quer que seja feito em segundo plano (ver Figura 27). São carregadas para a memória as informações dos vídeos que se encontram no banco de amostras exceto o vídeo com o nome informado ou o vídeo que estiver reconhecendo enquanto percorre todos os vídeos. Em seguido é exibida na tela as imagens do vídeo e os possíveis textos que se encontram na fala deste vídeo, conforme exibido na Figura 28. Juntamente com os textos possivelmente falados é exibida a pontuação do texto atribuído no algoritmo do filtro de Bayes.

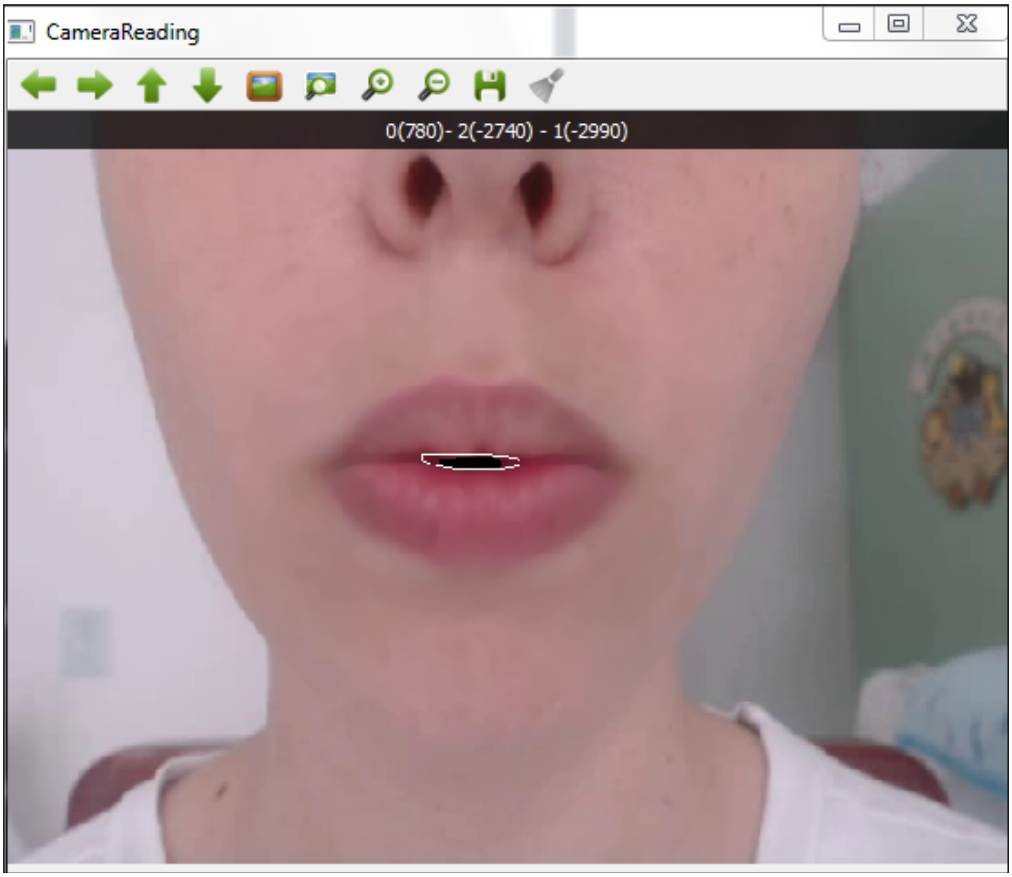

Figura 28 – Imagem apresentada durante o reconhecimento

3.4 RESULTADOS E DISCUSSÃO

Para o desenvolvimento do protótipo apresentado neste trabalho foram necessários testes com técnicas de processamento de imagem além de análise da viabilidade da implementação de classificação com técnicas de aprendizado de máquina. As próximas seções apresentam o cenário dos testes efetuados dentro do contexto de cada fase do processamento no reconhecimento da fala, sendo por último apresentados os resultados relativos à precisão, performance e memória da execução dos testes.

3.4.1 Gravação dos vídeos

Para a gravação dos vídeos foi utilizada a câmera Logitech C920 (resolução de 1080p com capacidade de 30 *Frames Per Second* (FPS), ou seja, trinta imagens por segundo). No

início dos testes foi identificado de forma geral que o processamento em imagens de alta resolução causa um aumento significativo no tempo de execução para as técnicas de processamento de imagem. Tendo em vista que há grande importância em ser efetuada a leitura labial em tempo real, estabeleceu-se a redução da qualidade das imagens para 640x480 pixels durante a captura.

Pode-se citar como grande problema encontrado na etapa de gravação dos vídeos a variação da taxa de imagens por segundo. A gravação das imagens de vídeo foi feita em ambientes onde a luz não incidisse diretamente na lente da câmera, pois causava redução da velocidade de captura. Além disso, devido à focalização da imagem automática pela câmera, os vídeos foram sujeitos a análise posterior para evitar que a focalização não fosse mal sucedida.

3.4.2 Definição da área de interesse e segmentação

Dada a tarefa de segmentação dos lábios, houve vários testes para estabelecer qual o método a ser utilizado para a localização da área de interesse, neste caso os lábios, e quais técnicas de processamento de imagem seriam utilizadas. Dado o fato de que a característica labial a ser utilizada no reconhecimento é o contorno, para maximizar a qualidade das imagens capturadas parte-se do pressuposto que o usuário se encontra com os lábios totalmente visíveis pela câmera de vídeo.

Inicialmente foi contemplada a ideia de utilização de técnicas de detecção de objetos com *Haar Cascades* (VIOLA; JONES, 2001) para a localização dos lábios. Porém, em muitas situações a técnica localizou não somente os lábios, mas também outras regiões da face ou ambiente. Foram feitos testes para a localização da face seguida da localização dos lábios, que apesar de se mostrarem estáveis, necessitariam a configuração dinâmica do tamanho do padrão utilizado nas buscas, o que inviabilizaria a implementação completa do protótipo no tempo determinado. Devido a este fato a localização da área de interesse, os lábios, foi feita de forma manual nos vídeos durante a fase de processamento pelo usuário.

Para a segmentação dos lábios foram testadas técnicas como *flood fill* (RUSS, 2011, p. 805) e *grabcut* (LAGANIÈRE, 2011, p. 137) ambos disponíveis na biblioteca OpenCV. Estes algoritmos visam segmentar imagens dados determinados pontos contendo áreas de interesse ou áreas indesejadas, seguindo assim um padrão de cores e estabelecendo a segmentação de acordo com a quantidade de áreas indicadas. Porém, devido o tempo de execução e dificuldade de automação da seleção das áreas de interesse, estes algoritmos foram descartados.

A solução final para a fase de segmentação optou por utilizar um conjunto de técnicas de processamento de imagem. Estas técnicas não se mostraram eficientes em um conjunto de cenários, sendo os mais notáveis os seguintes:

a) incidência da luz causando assimetrias: quando a luz não incide frontalmente na face do locutor há maior dificuldade no estabelecimento do contorno devido ao fato da utilização do modelo de cores HSV para a determinação de dentes da parte interna da boca do usuário;
b) ruídos faciais anatômicos: a existência de pelos faciais em grande quantidade causa problemas na descoberta da boca do usuário;
c) lábios do locutor muito claros: tendo em vista que os lábios são encontrados partindo de operações com limiarização, o protótipo não efetuou a limiarização inversa, portando, considerou que a cor dos lábios é mais intensa que o resto da pele;
d) excesso de luz frontal: o excesso de luz frontal pode também dificultar a limiarização HSV, fazendo com que a intensidade das cores seja muito semelhante, dificultando desta forma a segmentação dos dentes no interior da boca.

Tendo em vista a dificuldade na extração exata do contorno interno dos lábios, foi necessário conforme abordado previamente, a utilização da função na biblioteca OpenCV para a definição do polígono convexo dados os contornos obtidos da limiarização final. Desta forma foi possível suavizar o contorno e facilitar a extração de dados mais precisos em relação ao movimento dos lábios.

3.4.3 Extração dos dados do movimento dos lábios

Para a fase de extração das características dos lábios foram contempladas técnicas como fluxo óptico (LAGANIÈRE, 2011, p. 271) e pontos de interesse conforme explorado por Hojo e Hamada (2009), porém dada a complexidade e tipo da informação extraída, optou-se somente pela utilização do contorno interno dos lábios.

A utilização do contorno interno dos lábios foi escolhida com base no trabalho de Silveira, Facon e Borges (2003), que utilizou o contorno externo dos lábios para o reconhecimento da fala. A complexidade para a tarefa de obtenção do contorno externo ou interno pode ser considerada semelhante. Apesar de ser possível a extração do contorno externo com técnicas de limiarização em tons de cinza, existem ruídos que podem dificultar a tarefa. Da mesma forma, a obtenção do contorno interno possui uma complexidade semelhante, sendo

que neste trabalho, foi necessária a remoção dos dentes para obter um contorno interno constante. Além disso, foi escolhido o contorno interno com base em uma suposição de que este poderia ser mais semelhante entre pessoas diferentes. Porém os testes finais não puderam comprovar se esta suposição estava correta. Todavia, conforme apresentado previamente nos trabalhos correlatos, a utilização do contorno para o reconhecimento pode resultar em precisão inferior a técnicas como fluxo óptico utilizada por Shaikh et al. (2010) devido a quantidade de ruídos na extração do contorno.

Para armazenar os dados do movimento optou-se por armazenar a proporção entre uma imagem e outra subsequente a fim de obter uma medida que fosse invariável ao tamanho dos lábios em vídeos diferentes ou a resoluções de câmeras de vídeo diferentes, já que estes valores equivalem ao percentual de aumento ou diminuição do contorno labial. Dados os contornos dos lábios em um conjunto de imagens, a extração dos dados do movimento com base no contorno é facilmente extraída e permite que a fase de determinação do contorno possa ser melhorada com a evolução do protótipo em trabalhos futuros.

3.4.4 Classificação da fala

Para a etapa de classificação da fala foi testada a técnica chamada de Máquina de Vetores de Suporte (MVS) (VAPNIK, 1995). Porém, dadas as informações do movimento dos lábios, encontrou-se dificuldade em definir um formato de dados simples para o reconhecimento de padrões utilizando esta técnica. Além disso, foi detectado em testes iniciais que o treinamento de uma MVS é relativamente grande, constituindo de operações matemáticas complexas para a definição da separação dos dados treinados.

Para a classificação da fala foi utilizado, portanto, um algoritmo de baixa complexidade chamado de filtro de Bayes. Este algoritmo apresentou boa performance tanto na fase inicial de carregamento das amostras de movimentos quanto no reconhecimento, conforme será apresentado a seguir. Além disso, este algoritmo permite que em implementações futuras sejam incrementadas outras características da fala a fim de se obter maior precisão na comparação de movimentos dos lábios.

3.4.5 Execução de testes

Devido às dificuldades previamente expostas, foi criado somente um conjunto de testes que apresenta características favoráveis para validação da utilização do filtro de Bayes. Tendo a fase de segmentação apresentado dificuldades para a extração das informações do contorno, foi feita a gravação da fala somente com uma pessoa com o objetivo de maximizar os resultados em um cenário com alta qualidade.

Para a utilização do banco de amostras, foram capturadas 154 amostras de vídeo. Estas amostras são compostas de uma pessoa falando o texto com os numerais de zero a nove, sendo que cada um deles é repetido 14 vezes. Este texto falado nos vídeos foi utilizado com objetivo de obter parâmetros para a comparação com o trabalho de Silveira, Facon e Borges (2003), que utilizou amostras de vinte indivíduos distintos. Porém os resultados obtidos com este protótipo não foram efetuados com mais indivíduos, não sendo possível uma comparação significativa.

O tamanho da amostra e início da fala no grupo de amostras de vídeos coletados possui na maioria dos casos diferença significativa, e em alguns casos o tamanho pode diferir em aproximadamente 15 imagens entre um vídeo e outro para um mesmo texto.

Devido o fato de que o contorno labial é necessário e a velocidade da câmera pode ficar instável, foi solicitado ao usuário que gravou os vídeos que efetuasse a fala de forma clara e alta para que fosse possível observar os resultados e precisão com maior certeza da eficácia.

3.4.5.1 Precisão

O processo de verificação da precisão do protótipo foi composto pela execução de testes sendo que em cada um deles uma das amostras é retirada do grupo e as restantes são utilizadas para a busca com o filtro de Bayes. Sendo disponíveis 14 amostras para cada texto, foram executados para cada conjunto de textos 14 testes resultando para os 10 textos um total de 140 testes. Cada teste foi constituído da remoção de uma amostra e utilização das outras 13 como busca, assim como a remoção de uma amostra para cada um dos outros textos da área de busca. Este método de testes é chamado de *leave-one-out* e é indicado para quando o conjunto de amostras é pequeno (PARKER, 2011, p. 306).

Conforme pode ser visto no Quadro 15, dados os resultados de todos os testes, foram coletados os dados relativos ao texto o qual estava sendo feito o reconhecimento (Primeira

coluna vertical) em relação ao texto que foi encontrado (Primeira coluna horizontal). Sendo assim, conforme pode ser visto no Quadro 15, é possível identificar o percentual de acerto na linha diagonal, que apresenta os valores destacados, enquanto o restante dos valores representa o percentual de erro e confusão em relação aos outros textos da área de busca.

Texto	**“0”**	**“1”**	**“2”**	**“3”**	**“4”**	**“5”**	**“6”**	**“7”**	**“8”**	**“9”**
“0”	**0,64**	0,00	0,00	0,00	0,00	0,07	0,07	0,07	0,14	0,00
“1”	0,00	**0,64**	0,29	0,07	0,00	0,00	0,00	0,00	0,00	0,00
“2”	0,00	0,00	**0,86**	0,07	0,00	0,00	0,00	0,00	0,07	0,00
“3”	0,00	0,07	0,00	**0,93**	0,00	0,00	0,00	0,00	0,00	0,00
“4”	0,00	0,00	0,00	0,00	**0,93**	0,00	0,00	0,00	0,07	0,00
“5”	0,00	0,00	0,00	0,00	0,00	**0,93**	0,07	0,00	0,00	0,00
“6”	0,00	0,00	0,00	0,07	0,00	0,07	**0,79**	0,07	0,00	0,00
“7”	0,00	0,00	0,00	0,00	0,00	0,07	0,07	**0,79**	0,00	0,07
“8”	0,00	0,07	0,00	0,00	0,00	0,00	0,00	0,00	**0,93**	0,00
“9”	0,00	0,00	0,00	0,00	0,07	0,00	0,07	0,14	0,14	**0,57**

Quadro 15 - Matriz de confusão por texto

Como pode também ser observado no Quadro 15, o texto com o menor desempenho foi o ‘nove’, tendo um percentual equivalente a 57% de acerto. Este valor se encontra muito abaixo da média de acertos dos textos anteriores, que possuem uma média de 82,5% de acerto. Acredita-se que este erro ocorreu em função do movimento labial efetuado neste número, que é caracterizado por uma leve abertura e fechamento dos lábios que se repete duas vezes para esta palavra, sendo este padrão existente em outras amostras uma única vez.

Levando em consideração os valores que se encontram na diagonal e representam o acerto da classificação, pode-se obter a média de sucesso equivalente a 80%.

3.4.5.2 Desempenho

Os testes efetuados foram aplicados utilizando um computador convencional da marca Dell (Processador Core i5, 2.53GHz, 4GB memória) nestes testes, foi detectada a capacidade de reconhecimento com taxas médias de 20 até 25 imagens por segundo. Foram coletados os tempos médios das principais operações durante o reconhecimento conforme pode ser visualizado na Tabela 1. Os tempos apresentados foram extraídos observando o tempo médio de processamento em uma amostra de vídeo completa contendo 63 imagens.

Tabela 1 - Desempenho das principais etapas de processamento

DESEMPENHO INDIVIDUAL DAS PRINCIPAIS ETAPAS ENVOLVIDAS NO PROCESSAMENTO	
Etapa	**Tempo (milissegundos)**
Carregar banco de amostras em texto com dados de 130 amostras pré-processadas.	62,00
Filtro da Mediana inicial	16,70
Limiarização HSV	6,430
Filtro da Mediana após HSV	17,40
Erosão	0,110
Limiarização final com tons de cinza	0,045
Classificar Movimento	8,720

Conforme pode ser observado na Tabela 1, as operações de computação gráfica foram as que se mostraram mais onerosas, em especial, a aplicação do filtro da mediana nas duas etapas de processamento. A etapa de classificação que faz uso do filtro de Bayes demonstrou eficiência com o conjunto de amostras utilizado na busca, que foi composto de 130 vídeos, totalizando uma média de 6.000 registros de movimentos dos lábios.

3.4.5.3 Memória

O uso de memória foi observado em diferentes tamanhos durante a utilização do protótipo. Ao iniciar o teste com um único vídeo, o uso de memória ficou estável em 20MB. Porém, durante a execução dos testes em um único conjunto, sendo feita a classificação de 140 amostras, o protótipo fez uso de memória que chegaram a picos de 57MB. Especula-se que pode ter ocorrido algum vazamento de memória na implementação com o código em C++, ou que há problemas relacionados ao uso da biblioteca OpenCV.

A utilização de processamento ficou em níveis que equivalem a um total de 32% da capacidade computacional do computador utilizado nos testes, que conforme previamente exposto, possui um processador Core i5 com 2.53GHz e 4GB de memória.

4 CONCLUSÕES

Este trabalhou abordou a construção de um protótipo para reconhecimento de fala em vídeos, fazendo uso de tecnologias aplicadas para problemas de visão computacional.

Os resultados obtidos com este trabalho foram parcialmente satisfatórios, porém comprovam a possibilidade de desenvolvimento de uma aplicação para reconhecimento de fala em tempo real.

Tendo em vista que os testes efetuados foram feitos apenas com um indivíduo, não foi possível concluir se a fase de classificação obteria resultados eficientes com homogeneidade de amostras. O mesmo pode ser afirmado em relação às técnicas de segmentação dos lábios utilizadas.

A principal limitação atual da implementação se encontra na fase de segmentação dos lábios que exige a configuração de parâmetros durante uma fase de processamento. Além disso, com o crescimento do banco de amostras, é necessário alterar o tamanho dos grupos de elementos semelhantes (conforme apresentado na seção 3.3.2.5), que atualmente foi determinado a partir de testes.

Um dos maiores desafios durante a implementação deste protótipo foi o de equilibrar os esforços de desenvolvimento entre as duas principais etapas do processamento, que é a extração das características dos lábios, e o reconhecimento. Existindo inúmeras técnicas computacionais disponíveis para cada uma destas fases, foi necessária a escolha de técnicas que não fossem complexas e que permitissem a conclusão da implementação no tempo proposto.

4.1 EXTENSÕES

Como extensões para este trabalho, sugerem-se:

a) durante a fase de processamento dos vídeos gravados utilizar *Haar Cascades* para automatizar a localização da região de interesse que possui os lábios;
b) automatizar a escolha dos melhores parâmetros para extração do contorno. Sugere-se a utilização de descritores de contorno;
c) efetuar testes com vídeos com resoluções menores para que o tempo de processamento seja reduzido;

d) efetuar o reconhecimento da fala utilizando diretamente o dispositivo de entrada;
e) efetuar testes com homogeneidade de pessoas gravadas;
f) utilizar descrição do contorno dos lábios (ex. Fourier) como parâmetro de comparação durante a busca com o filtro de Bayes;
g) implementar alguma descrição com fluxo óptico como parâmetro de comparação durante a busca com o filtro de Bayes;
h) para efetuar reconhecimento em tempo real, utilizar um conjunto de instâncias do filtro de Bayes, sendo que cada instância é iniciada em tempos diferentes e destruída após determinado tempo;
i) melhorar o cálculo da qualidade da progressão da probabilidade nos vídeos utilizados no banco de dados do filtro de Bayes;
j) automatizar a definição do tamanho de grupos de elementos semelhantes de acordo com o banco de amostras para o filtro de Bayes;
k) reconhecer palavras isoladas a partir de frases que se encontram no banco de amostras. Pode-se fazer isso comparando os picos de probabilidade em cada vídeo e comparando o possível conteúdo no local onde essa probabilidade se encontra;
l) melhorar a percepção da velocidade no reconhecimento de fala pelo filtro de Bayes. Atualmente o filtro é muito sensível;
m) efetuar testes com dispositivos que possam efetuar a captura mais rápida. Atualmente o dispositivo utilizado nos testes limita-se a quantidade de imagens entre vinte e cinco e trinta por segundo;
n) atualizar a biblioteca OpenCV para a versão 2.4.3.

REFERÊNCIAS BIBLIOGRÁFICAS

ALEKSIC, Petar S.; KATSAGGELOS, Aggelos K. Lip feature extraction and features evaluation in the context of speech and speaker recognition. In: WEE-CHUNG LIEW, Alan; WANG, Shilin (Ed.). **Visual speech recognition**: lip segmentation and mapping. New York: Medical Information Science Reference, 2009. p. 39-69.

CAPLIER, Alice et al. Lip modelling and segmentation. In: WEE-CHUNG LIEW, Alan; WANG, Shilin (Ed.). **Visual speech recognition**: lip segmentation and mapping. New York: Medical Information Science Reference, 2009. p. 70-127.

ERBER, Norman P. Auditory-Visual perception of speech. **Journal of speech, language, and hearing research**, Illinois, v. 40, n. 4, p. 481-492, Nov. 1975.

HOJO, Hiroshi; HAMADA, Nozomu. Mouth motion analysis with space-time interest points. In: IEEE REGION 10 CONFERENCE, 4., 2009, Singapore. **Proceedings…** [S.l.]: IEEE, 2009. p. 327-330.

JAIN, Anil K.; ROSS, Arun A.; NANDAKUMAR, Karthik. **Introduction to biometrics**. New York: Springer, 2011.

KOLLER, Daphne; FRIEDMAN, Nir. **Probabilistic graphical models**: principles and techniques. London: The MIT Press, 2009.

LAGANIÈRE, Robert. **OpenCV 2 computer vision application programming cookbook**. Birmingham: Packt Publishing, 2011.

LIEBERMAN, Philip. Some effects of semantic and gramatical context on the production and perception of speech. **Language and speech**, [S.l.], v. 6, n. 3, p. 172-187, Jul./Set. 1963.

MARTINO, José M.; MAGALHÃES, Léo P. Um conjunto de visemas para uma cabeça falante do português do Brasil. In: CONGRESSO IBEROAMERICANO IBERDISCAP – TECNOLOGÍAS DE APOYO A LA DISCAPACIDAD, 3., 2004, San Jose. **Anais...** San Jose: EUNED, 2004. p. 198-203.

MCGURK, Harry; MACDONALD, John W. Hearing lips and seeing voices. **Nature**, London, v. 264, p. 746-748, Dez. 1976.

PARKER, Jim R. **Algorithms for image processing and computer vision**. Indianopolis: Wiley Publishing, 2011.

RUSS, John C. **The image processing handbook**. Boca Raton: RCR Press, 2011.

SENNYEY, Alexa L.; MONTIEL, José M.; CAPOVILLA, Fernando C. **Transtornos de aprendizagem**: da avaliação à reabilitação. São Paulo: Artes Médicas, 2008.

SHAIKH, Ayaz A. et al. Lip reading using optical flow and support vector machines. In: CONGRESS ON IMAGE AND SIGNAL PROCESSING, 3., 2010, Yantai. **Proceedings…** Yantai: RMIT, 2010. p. 327-330.

SHAPIRO, Linda. **Computer vision**. Seatle: Prentice Hall, 2001.

SILVEIRA, Luciana G. da; FACON, Jacques; BORGES, Díbio L. Visual speech recognition: a solution from feature extraction to words classification. In: SIMPÓSIO DE COMPUTAÇÃO GRÁFICA E PROCESSAMENTO DE IMAGENS, 16., 2003, São Carlos. **Anais…** São Carlos: SIBGRAPI, 2003. p. 339-405.

SUMMERFIELD, Quentin. Lipreading and audio-visual speech perception. **Processing the facial image**, London, v. 335, n. 1273, p. 71-78, Jan. 1992.

THRUN, Sebastian; BURGARD, Wolfram; FOX, Diete. **Probabilistic robotics**. [S.l.]: The MIT Press, 2005.

VAPNIK, Vladimir. **The nature of statistical learning theory**. Berlin: Springer-Verlag, 1995.

VIOLA, Paul; JONES, Michael. Rapid object detection using a boosted cascade of simple features. In: CONFERENCE ON COMPUTER VISION AND PATTERN RECOGNITION, 15., 2001, Kauai. **Proceedings…** Kauai: Computer Society, 2001. p. 511-518.

WANG, Shilin et al. Lip segmentation with complex background. In: WEE-CHUNG LIEW, Alan; WANG, Shilin (Ed.). **Visual speech recognition**: lip segmentation and mapping. New York: Medical Information Science Reference, 2009. p. 150-171.

YAU, Wai C.; KUMAR, Dinesh K.; WEGHORN, Hans. Motion features for visual speech recognition. In: WEE-CHUNG LIEW, Alan; WANG, Shilin (Ed.). **Visual speech recognition**: lip segmentation and mapping. New York: Medical Information Science Reference, 2009. p. 388-415.